

Diseño y evaluación comparativa de modelos predictivos para el cribado prenatal del síndrome de Down mediante técnicas de aprendizaje automático.



Universitat
Oberta
de Catalunya



UNIVERSITAT_{DE}
BARCELONA

David Garcerán Herráiz

MU Bioinf. y Bioest.

Aprendizaje automático

Nombre Tutor/a de TF

Romina Astrid Rebrij

**Profesor/a responsable de la
asignatura**

Agnès Pérez Millan

Fecha Entrega 03/06/2026



Esta obra está sujeta a una licencia de
Reconocimiento-NoComercial [3.0 España de
Creative Commons](https://creativecommons.org/licenses/by-nc/3.0/es/)

FICHA DEL TRABAJO FINAL

Título del trabajo:	Diseño y evaluación comparativa de modelos predictivos para el cribado prenatal del síndrome de Down mediante técnicas de aprendizaje automático.
Nombre del autor:	David Garcerán Herráiz
Nombre del director/a:	Romina Astrid Rebrij
Nombre del PRA:	Agnès Pérez Millan
Fecha de entrega (mm/aaaa):	06/2026
Titulación o programa:	M.U. Bioestadística y Bioinformática
Área del Trabajo Final:	Aprendizaje Máquina
Idioma del trabajo:	Castellano
Palabras clave	Síndrome de Down, aprendizaje automático, <i>screening</i> prenatal
Resumen del Trabajo	
Este trabajo aborda el diseño y evaluación de modelos de aprendizaje automático aplicados al cribado prenatal del síndrome de Down, con el objetivo de superar las limitaciones de linealidad e independencia asumidas por los modelos estadísticos convencionales. La metodología se desarrolló a partir de los datos reales del Hospital Lluís Alcanyís (FISABIO). Tras estandarizaciones, corrección por peso materno y tratamiento de valores extremos, se compararon seis familias de clasificadores bajo un esquema de validación cruzada anidada, calibración de probabilidades y optimización específica para escenarios desbalanceados. Adicionalmente, se implementó una arquitectura de ensamblado jerárquico (stacking) combinando un SVC para el primer trimestre y un Random Forest para el segundo, complementada con técnicas de interpretabilidad global mediante SHAP y ALE. Los resultados muestran la superioridad del modelo STACK, que alcanzó una sensibilidad del 81% para una tasa de falsos positivos del 5% y una ratio de verosimilitud positiva de 19.06. El análisis interpretativo confirmó que el modelo captura patrones biológicamente plausibles, como el acortamiento femoral, incremento de la translucencia nucal o la disminución de PAPP-A entre otros. En conjunto, los resultados sugieren que el ensamblado modular combina correctamente la información de ambos trimestres y genera estimaciones de riesgo suficientemente fiables para su potencial uso como herramienta de apoyo al cribado prenatal.	

Abstract

This work addresses the design and evaluation of machine learning models applied to prenatal screening of Down syndrome, aiming to overcome the linearity and independence assumptions underlying conventional statistical models.

The methodology was developed using real-world data from Hospital Lu s Alcany s (FISABIO). After standardization, weight correction, and robust treatment of extremes values, six classifier families were compared under a nested cross-validation framework with probability calibration and optimization tailored to imbalanced settings. Additionally, a hierarchical ensemble architecture (stacking) was implemented, combining a SVC for the first trimester and a Random Forest for the second trimester, complemented by global interpretability techniques based on SHAP and ALE.

Results demonstrate the superiority of the STACK model, which achieved 81% sensitivity at a fixed 5% false positive rate and a positive likelihood ratio of 19.06. Interpretability analyses confirmed that the model captures biologically plausible patterns, including femoral shortening, increased nuchal translucency, and decreased PAPP-A levels. Overall, the results suggest that the modular ensemble effectively integrates information from both trimesters and generates sufficiently reliable risk estimates for its potential use as a decision-support tool in prenatal screening.

Contenido

1.	Introducción	1
1.1.	Contexto y justificación del trabajo	1
1.2.	Objetivos del Trabajo.....	2
1.3.	Impacto en sostenibilidad, ético-social y de diversidad	3
1.4.	Enfoque y método seguido	4
1.5.	Planificación del Trabajo	5
1.6.	Breve resumen de productos obtenidos.....	7
1.7.	Breve descripción de los otros capítulos de la memoria	7
1.8.	Declaración sobre el uso de inteligencia artificial generativa	7
2.	Estado del arte	9
3.	Materiales y métodos.....	12
3.1.	Datos y población de estudio.....	12
3.2.	Preprocesado de los datos	12
3.3.	Diseño experimental y particionados	16
3.4.	Calibración de probabilidades	19
3.5.	Métricas de evaluación.....	20
3.6.	Implementación	23
3.7.	Interpretabilidad.....	23
4.	Resultados.....	25
4.1.	Escenario del primer trimestre	27
4.2.	Escenario del segundo trimestre	29
4.3.	Escenario combinado	32
5.	Discusión	36
5.1.	Plausibilidad clínica de las variables predictoras	36
5.2.	Comparativa y posicionamiento.....	37
5.3.	Limitaciones	38
6.	Conclusiones y trabajos futuros	40
6.1.	Conclusiones.....	40
6.2.	Consecución de objetivos.....	41
6.3.	Trabajos futuros	42
7.	Glosario	43
8.	Bibliografía.....	44
9.	Anexo	46

LISTA DE FIGURAS

Figura 1 Diagrama de Venn	13
Figura 2 Corrección de PAPP-A y HCG según peso.....	15
Figura 3 Gráficos de barras comparativos sobre las técnicas de muestreo.....	17
Figura 4 Distribución de variables	25
Figura 5 Matriz de correlación del primer trimestre	26
Figura 6 Matriz de correlación del segundo trimestre.....	26
Figura 7 Comparación de modelos en 1T	27
Figura 8 Calibración de SVC en 1T.....	28
Figura 9 SHAP resumen de SVC en 1T.....	29
Figura 10 Efectos ALE de SVC en 1T.....	29
Figura 11 Comparación de modelos en el 2T	30
Figura 12 Calibración de RF en 2T	30
Figura 13 SHAP resumen de RF en 2T	31
Figura 14 Efectos ALE de RF en 2T	31
Figura 15 ALE de la interacción DBP y perímetro cefálico	32
Figura 16 Comparación de modelos en escenario combinado.....	32
Figura 17 Calibración de escenario combinado	33
Figura 18 Comparación de STACK.....	34
Figura 19 SHAP resumen de STACK	35
Figura 20 Efectos ALE de STACK	35

LISTA DE TABLAS

Tabla 1: Intervalos de truncamiento según MAD.....	15
Tabla 2 Librerías utilizadas	23
Tabla 3 Métricas OOF en 1T.....	28
Tabla 4 Métricas OOF en el 2T	30
Tabla 5 Métricas OOF en el escenario combinado	33
Tabla 6 Métricas en TEST con bootstrap.....	34

1. Introducción

1.1. Contexto y justificación del trabajo

El síndrome de Down es la anomalía cromosómica más frecuente compatible con la vida y es una de las razones principales por las que se realizan programas de cribado prenatal. La identificación precoz de fetos con mayor riesgo mediante cribado permite minimizar las pruebas diagnósticas invasivas. [1]

En la práctica clínica, el cribado prenatal del síndrome de Down se basa en la combinación de información procedente de diferentes momentos del embarazo. Durante el primer trimestre, se integran variables maternas, marcadores ecográficos y determinaciones bioquímicas para estimar el riesgo individual mediante modelos estadísticos. Posteriormente, en el segundo trimestre, la información ecográfica se emplea para modificar dicho riesgo inicial. [2]

Estos modelos han alcanzado niveles de rendimiento elevados, con tasas de detección que rondan del 90% al 95%, para tasas de falsos positivos del 2% al 5% [2]. Sin embargo, presentan limitaciones derivadas de los supuestos estadísticos en los que se basan, como la linealidad, la independencia entre variables o la aplicación secuencial de la información, que pueden no reflejar adecuadamente la complejidad de los datos clínicos.

En este contexto, el aprendizaje automático ha emergido como una herramienta capaz de modelizar relaciones no lineales y patrones complejos, mostrando resultados prometedores en distintos ámbitos de la medicina. No obstante, su aplicación en el cribado prenatal continúa siendo limitada, especialmente en lo relativo a la integración de variables heterogéneas obtenidas en diferentes momentos del proceso clínico. [1]

Justificación

El desarrollo de modelos predictivos en el ámbito clínico no debe centrarse únicamente en la mejora del rendimiento, sino también en la adecuación metodológica del proceso de modelización. En particular, la selección de variables, la estructura del modelo, las técnicas de validación y la interpretación de los resultados son aspectos críticos que condicionan la validez y la aplicabilidad de los modelos en la práctica clínica [3].

En el caso que nos compete, la información disponible presenta características específicas que plantean desafíos interesantes: heterogeneidad de las variables, posible correlación entre ellas, cronología de su obtención y el desbalanceo inherente de la variable respuesta (binaria), que indica la presencia o ausencia de síndrome de Down confirmada mediante diagnóstico clínico o prueba genética. Estas características pueden influir en el rendimiento de los modelos y en su capacidad de generalización.

Por ello, se plantea la necesidad de realizar un análisis metodológico de los modelos predictivos aplicados al cribado prenatal del síndrome de Down, que permita evaluar críticamente los enfoques utilizados, identificar posibles limitaciones y explorar alternativas.

El presente trabajo se sitúa en este contexto, proponiendo el desarrollo y evaluación de un modelo predictivo de clasificación binaria supervisada basado en aprendizaje automático, con especial atención a la justificación metodológica de las decisiones adoptadas y su impacto en el rendimiento del modelo.

Descripción del trabajo

En este trabajo se aborda el problema del cribado prenatal del síndrome de Down mediante el desarrollo y evaluación de modelos predictivos basados en aprendizaje automático. Para ello, se emplea una base de datos clínica que recoge información procedente del seguimiento del embarazo, incluyendo variables maternas, marcadores ecográficos y determinaciones bioquímicas obtenidas en diferentes modelos del proceso prenatal.

El objetivo es analizar el rendimiento de distintos enfoques de modelización en la predicción del riesgo de anomalías cromosómicas, teniendo en cuenta las características específicas de los datos clínicos, como la heterogeneidad de las variables, la posible correlación entre ellas y el desbalanceo de la variable respuesta.

Asimismo, se realizará un análisis metodológico de las decisiones adoptadas en el proceso de modelización, evaluando el impacto de aspectos como la selección de variables, la estructura de los modelos y las técnicas de evaluación empleadas. Este análisis permitirá identificar posibles limitaciones y explorar alternativas que puedan mejorar la robustez y la interpretabilidad de los modelos.

Finalmente, se pretende valorar la utilidad del modelo desarrollado en el contexto clínico, considerando su capacidad para mejorar la estimación del riesgo en el cribado prenatal del síndrome de Down y su posible integración en la práctica asistencial.

1.2. Objetivos del Trabajo

1. Analizar y caracterizar las variables clínicas y ecográficas disponibles en el *screening* prenatal del síndrome de Down, evaluando su relevancia y distribución en la población de estudio.
 - a. Describir estadísticamente las variables de primer y segundo trimestre, incluyendo distribución, correlaciones y desbalance de clases.
 - b. Evaluar la relación de cada variable con la presencia o ausencia de anomalías cromosómicas, identificando aquellas con mayor potencial predictivo.
2. Desarrollar y evaluar modelos predictivos para la estimación del riesgo durante el embarazo.
 - a. Implementar algoritmos de aprendizaje automático.
 - b. Comparar rendimiento mediante métricas oportunas.
 - c. Evaluar la estabilidad y generalización mediante validación cruzada estratificada o técnicas de muestreo.
3. Analizar críticamente las decisiones metodológicas del proceso de modelización y proponer mejoras potenciales.
 - a. Revisar estructura de los modelos, selección de variables y cronología de su incorporación, evaluando su justificación metodológica.
 - b. Explorar posibles estrategias de mejora, como calibración de probabilidades o ajuste de la arquitectura modular, y evaluar su impacto.
 - c. Documentar recomendaciones metodológicas para futuras aplicaciones clínicas del modelo predictivo.

1.3. Impacto en sostenibilidad, ético-social y de diversidad

1.3.1 Sostenibilidad

El desarrollo del presente trabajo se enmarca en el ámbito del análisis de datos y la construcción de modelos de aprendizaje automático, lo cual implica un consumo de recursos computacionales y energéticos asociados al entrenamiento.

Desde el punto de vista ambiental, el principal impacto negativo proviene del uso de infraestructuras de computación, que conlleva consumo energético y, potencialmente, emisiones indirectas de CO₂. No obstante, este impacto se considera limitado debido a que: (a) los modelos empleados son de complejidad moderada, (b) el entrenamiento se produce en entornos locales y de bajo consumo, (c) no se utilizan arquitecturas de alto coste computacional.

Como impacto positivo, el uso de modelos predictivos puede contribuir a una mejor toma de decisiones basada en datos, lo que potencialmente reduce ineficiencias en procesos y uso de recursos. Este trabajo se alinea principalmente con:

- ODS 9 (Industria, innovación e infraestructura), al desarrollar soluciones basadas en datos.
- ODS 12 (Producción y consumo responsables), al favorecer decisiones más eficientes.

1.3.2 Comportamiento ético y responsabilidad social

El trabajo implica el uso de datos y el desarrollo de modelos predictivos, lo que plantea varias consideraciones éticas relevantes.

En primer lugar, el uso de datos requiere garantizar el cumplimiento de la normativa vigente en materia de protección de datos, en particular el Reglamento General de Protección de Datos (RGPD) [4]. En este sentido, el trabajo se desarrolla respetando acuerdos de confidencialidad establecidos con las entidades proveedoras de datos, lo que implica limitaciones en el acceso, uso y difusión de la información. A su vez, se garantiza el uso de datos anonimizados o pseudo anonimizados, minimizando el riesgo de identificación de individuos.

En segundo lugar, los modelos desarrollados pueden ser utilizados como herramientas de apoyo a la decisión. Esto implica el riesgo de uso indebido de los resultados, interpretaciones incorrectas o automatización de decisiones sin supervisión humana. Para mitigar estos riesgos, el trabajo presenta los modelos como herramientas de apoyo, no sustitutivas del criterio experto; evalúa el rendimiento de forma rigurosa, evitando conclusiones no justificadas; y documenta limitaciones de los modelos.

Como impacto positivo, el trabajo contribuye a la mejora de toma de decisiones basada en evidencia, lo que puede tener beneficios sociales en ámbitos como la salud, la gestión o la investigación. Este trabajo se alinea con:

- ODS 8 (Trabajo decente y crecimiento económico).
- ODS 3 (Salud y bienestar).

1.3.3 Diversidad

El uso de modelos de aprendizaje automático puede introducir o amplificar sesgos presentes en los datos, lo que puede afectar de forma desigual a distintos colectivos [5,6].

En este trabajo se reconoce el riesgo de sesgos en los datos de entrada, diferencias en el rendimiento del modelo entre grupos y reproducción de desigualdades existentes. Para abordar estos riesgos se realiza un análisis exploratorio que permite identificar posibles desequilibrios, se evalúan modelos con métricas adecuadas y se reconoce la necesidad de análisis específicos de equidad si el contexto de aplicación lo requiere. En relación con la perspectiva de género, aunque el problema abordado se centra en el análisis de datos del embarazo y, por tanto, en una población específica; no se realiza un análisis explícito de posibles sesgos relacionados con variables de género y otros factores de diversidad. No obstante, se considera conveniente evaluar el comportamiento del modelo en distintos subgrupos poblacionales, incluyendo factores sociodemográficos, con el fin de garantizar un uso equitativo de la herramienta.

Asimismo, se evita el uso de variables sensibles cuando no están justificadas, y se promueve una interpretación crítica de los resultados. En cuanto al lenguaje y la documentación, se procura un uso inclusivo y respetuoso, evitando sesgos en la representación de colectivos. Este trabajo se alinea con:

- ODS 10 (Reducción de desigualdades).

1.4. Enfoque y método seguido

Para llevar a cabo este trabajo se seguirán dos líneas generales: por un lado, la revisión de la literatura sobre modelos predictivos en el cribado prenatal del síndrome de Down; por otro, la preparación y análisis de la base de datos clínica disponible, que incluye variables maternas, marcadores ecográficos y bioquímicos obtenidos durante el primer y segundo trimestre del embarazo.

En una primera fase se realizará un preprocesado de los datos, incluyendo limpieza, codificación de variables y la identificación de posibles valores faltantes o inconsistentes, dotando al conjunto de datos de estructura.

A continuación, se explorará la relación de las variables explicativas con la presencia o ausencia de síndrome de Down, identificando patrones relevantes y seleccionando las variables con mayor potencial predictivo. Se incluye análisis estadísticos descriptivos y evaluaciones de correlación entre variables, así como la consideración de la distribución de la variable respuesta y del desbalance entre clases.

En la fase de modelización, se desarrollará y evaluará el (los) algoritmo de aprendizaje automático adecuado para problemas de clasificación binaria supervisada. Se validará mediante técnicas de validación cruzada estratificada, de manera que se mantenga la proporción de clases en cada partición. Se aplicarán métricas de rendimiento oportunas para permitir la comparación objetiva entre enfoques.

Posteriormente, se llevará a cabo un análisis metodológico de las decisiones adoptadas en el proceso de modelización, evaluando el impacto de la selección de variables, la estructura de los modelos y las estrategias de validación sobre los resultados obtenidos. Se explorarán posibles mejoras, incluyendo calibración de probabilidades y ajustes de parámetros, siempre evaluando su efecto en la capacidad predictiva y la robustez de los modelos.


Finalmente, todos los resultados obtenidos serán documentados en un informe que refleje tanto el procedimiento seguido como los hallazgos derivados del análisis, garantizando la reproducibilidad del trabajo y facilitando su integración en futuras aplicaciones clínicas o estudios complementarios.

1.5. Planificación del Trabajo

Tareas

1. Preparación y análisis de los datos.
 - a. Organización de la base de datos disponible.
 - b. Limpieza de datos, faltantes, inconsistencias y codificación.
 - c. Análisis descriptivo de las variables.
 - d. Estudio de la distribución de clases y del posible desbalance.
 - e. Análisis de correlación entre variables y redundancias.
 - f. Preparación del conjunto final para su uso en modelos.
2. Desarrollo y evaluación de modelos predictivos.
 - a. Definición del esquema de validación.
 - b. Implementación de distintos algoritmos de clasificación.
 - c. Entrenamiento de los modelos.
 - d. Evaluación del rendimiento mediante métricas oportunas.
 - e. Comparación de los modelos desarrollados.
 - f. Selección del modelo o modelos con mejor comportamiento.
3. Análisis metodológico y mejora del modelo.
 - a. Revisión de la literatura.
 - b. Análisis crítico de las decisiones.
 - c. Evaluar el impacto de diferentes enfoques.
 - d. Exploración de posibles mejoras.
 - e. Comparación e interpretación de los resultados.
4. Documentación y redacción del trabajo.
 - a. Elaboración del marco teórico y estado del arte.
 - b. Redacción de la metodología y descripción del proceso seguido.
 - c. Discusión de resultados y análisis de limitaciones.
 - d. Redacción de conclusiones y líneas futuras de investigación.

Calendario



Hitos

Hito	Descripción	Fecha
1	Presentación del plan de trabajo: PEC1	04/03/2026
2	1: Preparación y análisis de los datos	
3	Informe fase 1: PEC2	01/04/2026
4	2: Desarrollo y evaluación de modelos	
5	Informe fase 2: PEC3	06/05/2026
6	3: Análisis metodológico	transversal
7	4: Documentación y redacción.	transversal
8	Entrega de memoria: PEC4	03/06/2026
9	Presentación: PEC5	10/06/2026
10	Defensa	¿?

Análisis de riesgos

Los posibles problemas que pueden surgir pueden ser:

- Problemas de software: Incompatibilidades en librerías o errores en dependencias. Una mitigación sería dedicar tiempo a depuración, mantener entornos virtuales y copias de seguridad.
- Problemas asociados a la planificación: Limitación de horas efectivas de dedicación, posibles retrasos, imprevistos o sobrecarga. Las posibles mitigaciones podrían ser trabajar en bloques, priorizar tareas y ajustar el cronograma de ser necesario.
- Problemas relacionados con el conocimiento del área: Dificultad para interpretar marcadores ecográficos o bioquímicos y su relación con el riesgo de síndrome de Down desde una perspectiva teórica. La solución reside en revisar literatura científica o consultar a profesionales.

1.6. Breve resumen de productos obtenidos

En este trabajo se han generado diversos productos técnicos:

- Modelos predictivos especializados por trimestre
- Arquitectura de ensamble jerárquico
- Framework de evaluación y calibración
- Código fuente

1.7. Breve descripción de los otros capítulos de la memoria

En este apartado se presenta una síntesis de la estructura del trabajo:

- **Estado del arte:** Se realiza una revisión de las estrategias actuales de cribado prenatal del SD. Se analizan desde los métodos convencionales hasta las aplicaciones emergentes de aprendizaje automático.
- **Materiales y métodos:** Describe el origen de los datos clínicos y el proceso del preprocesado. Se detalla el diseño experimental, la optimización de hiper parámetros, la calibración de probabilidades y las técnicas de interpretabilidad empleadas en los modelos.
- **Resultados:** Expone el rendimiento de los clasificadores en los escenarios de primer trimestre, segundo trimestre y combinado. Incluye la comparación final de las arquitecturas de stacking y la evaluación del modelo final seleccionado.
- **Discusión:** Se interpretan los hallazgos desde una perspectiva clínica y técnica, contrastando resultados con la literatura científica.
- **Conclusiones y trabajos futuros:** Resume las aportaciones principales del trabajo, evalúa el cumplimiento de los objetivos iniciales y propone nuevas líneas de investigación.
- **Glosario, Bibliografía y Anexos.**

1.8. Declaración sobre el uso de inteligencia artificial generativa

Durante la concepción, desarrollo y redacción del presente trabajo se han utilizado diversas herramientas de IA generativa como apoyo metodológico, técnico y lingüístico, siempre bajo supervisión y validación crítica.

En la fase de revisión bibliográfica se empleó Scispace como herramienta de apoyo para la búsqueda y exploración inicial de literatura científica relevante, facilitando la localización de artículos y navegación entre referencias relacionadas.

Durante la redacción de la memoria se utilizó ChatGPT como asistente de apoyo lingüístico y estructural, principalmente para revisión gramatical, mejora de claridad expositiva, reformulación o sugerencias de cohesión textual. En ningún caso se delegó en la herramienta la generación autónoma del contenido científico, análisis de resultados, interpretación o conclusiones.

En el desarrollo del código y análisis computacional se emplearon herramientas como Codex y Claude como soporte para tareas de refactorización, depuración, limpieza de código, sugerencias de modulación y consultas puntuales de implementación en Python. Todo el código generado de este modo ha sido revisado, adaptado y comentado.

Se considera que estas herramientas han aportado mejoras relevantes en productividad, apoyo a la redacción, depuración y organización del flujo de trabajo. Sin embargo, presentan limitaciones importantes, como generación ocasional de referencias erróneas, o errores varios.

2. Estado del arte

El cribado prenatal del síndrome de Down representa un pilar fundamental en la atención obstétrica moderna, evolucionando desde la simple evaluación de la edad materna hacia protocolos multivariantes de alta precisión. En esa sección se pretende analizar el estado del arte de las estrategias de cribado, comparando los métodos convencionales basados en marcadores bioquímicos y ecográficos con las emergentes aplicaciones de inteligencia artificial. Los modelos clásicos, fundamentados en Múltiplos de la Mediana (MoM) y razones de verosimilitud, alcanzan tasas de detección de hasta el 94% mediante el “*Integrated Test*”, aunque presentan limitaciones en términos de tasas de falsos positivos y dependencia de calibraciones locales [1,2].

La incorporación de algoritmos de aprendizaje automático, tales como Random Forest, Máquinas de Soporte Vectorial y arquitecturas de ensamble en cascada, ofrece una capacidad superior para gestionar la complejidad y el desbalance inherente a los datos clínicos. No obstante, la transición hacia estos modelos requiere abordar desafíos críticos de interpretabilidad y validación clínica.

Problema clínico

El síndrome de Down (SD), o trisomía 21, es la aneuploidía fetal más prevalente a nivel mundial [2]. Su incidencia global se estima aproximadamente en 1 de cada 700 a 1000 nacimientos, aunque esta cifra varía significativamente según la distribución de la edad materna en la población [1]. Su detección temprana es crucial para permitir un asesoramiento genético adecuado, facilitar la toma de decisiones informadas por parte de los padres y optimizar la planificación del manejo perinatal [2].

Es fundamental distinguir entre las pruebas de cribado y las pruebas diagnósticas: el cribado (screening) son pruebas no invasivas (bioquímica materna, ecografía) aplicadas a la población general para estratificar el riesgo, su objetivo no es confirmar la enfermedad sino identificar a los fetos con una probabilidad significativamente alta de estar afectados para ofrecerles pruebas confirmatorias [2,7]. Por otra parte, las pruebas diagnósticas son procedimientos invasivos como la amniocentesis o la biopsia de vellosidades coriales (CVS) que analizan directamente el cariotipo fetal. Aunque definitivos, conllevan riesgos de pérdida fetal de entre 0.5 – 1% [2] y costes elevados (entre 700 y 1000 euros en Europa) [8,9]. El objetivo clínico del cribado es maximizar la tasa de detección mientras se minimiza la tasa de falsos positivos (FPR) para reducir intervenciones invasivas innecesarias [1,10].

Métodos actuales de cribado

Los programas de cribado se organizan principalmente según el momento de la gestación en que se realizan las mediciones de biomarcadores séricos como la Proteína plasmática A asociada al embarazo (PAPP-A), la gonadotropina coriónica humana (hCG), el estriol no conjugado (uE3) o Inhibina A; también se miden marcadores ecográficos como la translucencia nucal (NT), la longitud cefalocaudal (CRL), el diámetro biparietal (DBP), perímetro cefálico y abdominal o la longitud del fémur (LF).

El cribado del primer trimestre (Semanas 10-13) utiliza una combinación de marcadores bioquímicos (PAPP-A y β -hCG libre) y la NT. Este enfoque alcanza una tasa de detección del 85% con un 5% de falsos positivos [2].

El cribado del segundo trimestre (Semanas 15-20) se basa tradicionalmente en el “Triple Test” (AFP, hCG y uE3) o el “Quadruple Test” (añadiendo Inhibina A). La prueba cuádruple identifica el 76% de los casos con un 5% de FPR [2]. La fiabilidad del triple test es menor, con detecciones estimadas entre el 60% y 65% [11].

El cribado integrado combina marcadores del primer y segundo trimestre en un único cálculo de riesgo al final del proceso. Es considerado el estándar, logrando una detección del 94% con un 5% de FPR [2].

Un avance revolucionario en los métodos actuales de cribado ha sido la introducción de las pruebas de ADN fetal libre en sangre materna, también denominadas NIPT. Esta tecnología se basa en la detección y análisis de ácidos nucleicos de origen fetal que circulan en el plasma materno. Mediante técnicas de alta sensibilidad como la secuenciación masiva paralela o la PRC digital, el cfDNA logra una precisión diagnóstica que roza el 100% de sensibilidad y especificidad en la detección de SD [1].

Modelos clásicos de riesgo: Fundamentos y limitaciones

Debido a que las concentraciones de los biomarcadores varían con la edad gestacional, los modelos clásicos normalizan los valores brutos dividiéndolos por la mediana esperada para esa semana de embarazo, obteniendo los MoM. Este ajuste permite estandarizar las mediciones y corregirlas por factores como el peso materno, origen étnico o tabaquismo [1,7].

El riesgo final se estima utilizando el teorema de Bayes. El riesgo inicial (basado en la edad materna) se multiplica por las razones de verosimilitud (LR) de cada marcador observado. Estos algoritmos paramétricos asumen una distribución log-normal de los marcadores en poblaciones afectadas y no afectadas [9,12–14].

Sin embargo, estos modelos tienen algunas limitaciones como (a) la sensibilidad a medianas locales, ya que dependen de la precisión de las medianas poblacionales utilizadas por el laboratorio, lo que dificulta la transferibilidad entre centros sin calibración [15]; (b) gestión de correlaciones: tienen dificultades para manejar interacciones complejas y no lineales entre marcadores, así como la correlación inherente entre variables bioquímicas [2,10,14]; (c) tasas de falsos positivos: aunque efectivos, el FPR del 5% sigue implicando un número considerable de pruebas invasivas en fetos sanos, con el consiguiente estrés parental y riesgo clínico [2,7,16].

Aprendizaje automático en el screening prenatal

Su uso busca superar las limitaciones de los modelos estadísticos tradicionales mediante el análisis de patrones complejos en grandes volúmenes de datos. Los algoritmos evaluados incluyen:

- Máquinas de Soporte Vectorial (SVM), redes neuronales artificiales (ANN): han demostrado capacidad para mejorar la precisión diagnóstica frente a modelos de regresión estándar [8,9].
- Random Forest y Gradient Boosting: Utilizados para identificar la importancia de las características y manejar datos heterogéneos [11].
- Modelos de ensamble y cascada: Enfoques como CVIFLR [10] se han diseñado específicamente para gestionar datos con correlación de características y desbalance extremo de clases.

Las métricas estándar para evaluar estos modelos incluyen el área bajo la curva ROC (AUROC), la sensibilidad (DR) y el área bajo la curva de “precision-recall” (AUPRC), esta última es crucial debido a la baja prevalencia del SD [9,10].

Estos estudios han reportado mejoras en la detección, alcanzando en algunos marcos experimentales valores de DR superiores al 90%, superando a las ecuaciones de mediana de laboratorio tradicionales [8,10,14,15].

El manejo del desbalance de datos es crítico; técnicas como SMOTE, SMOTEENN y el uso de Isolation Forests para detectar anomalías antes de la clasificación final han demostrado ser eficaces para reducir sesgos y mejorar el rendimiento [10].

Posicionamiento

Un enfoque modular, como el propuesto por arquitecturas de ensamble en cascada, ofrece robustez al combinar múltiples clasificadores, reduciendo el riesgo de sobreajuste y aumenta estabilidad. Los modelos tipo “Hybrid Prediction” permiten integrar etapas específicas para tratar el desbalance sin comprometer la especificidad general. Otra ventaja importante es la flexibilidad para actualizaciones parciales [10,15].

La “caja negra” de los modelos complejos de ML es una barrera para la adopción, la interpretabilidad es fundamental para que el facultativo comprenda el porqué de un riesgo elevado [7,11,15].

Herramientas como SHAP o LIME se mencionan como métodos necesarios para justificar predicciones individuales basados en el peso de cada biomarcador [15].

En este contexto, el presente trabajo propone una arquitectura modular basada en *stacking* que integra de forma implícita la información del primer y segundo trimestre, preservando la naturaleza complementaria de ambos escenarios. El estudio se desarrolla sobre datos clínicos reales procedentes de práctica asistencial real, aportando mayor realismo metodológico frente a trabajos realizados sobre cohortes altamente controladas o contextos experimentales menos representativos.

Se implementa un *pipeline* experimental riguroso basado en validación cruzada anidada, calibración probabilística y optimización multiobjetivo orientada a restricciones clínicas de bajo falso positivo, alineando el diseño metodológico con el objetivo operativo real del cribado prenatal.

Finalmente, el trabajo incorpora una capa de interpretabilidad funcional mediante SHAP y ALE, permitiendo evaluar el rendimiento predictivo y verificar que los modelos capturan patrones biológicamente plausibles y coherentes con el fenotipo del SD.

En conjunto, estos elementos posicionan al trabajo como una aproximación metodológica integradora que combina rendimiento, robustez e interpretabilidad dentro de un problema clínico de alta relevancia.

3. Materiales y métodos

3.1. Datos y población de estudio

Los datos utilizados en este estudio fueron cedidos y proporcionados por el grupo “xàtivaperinatal-FISABIO” del Hospital Lluís Alcanyís (Departamento de Salut Xàtiva-Ontinyent, Comunidad Valenciana, España). El conjunto de datos incluye 3762 registros correspondientes a 2937 embarazos únicos, lo que implica la presencia de datos longitudinales para algunos casos.

La variable objetivo es la presencia de SD, definida de forma binaria (control vs. caso); en la que todos los casos positivos han sido confirmados mediante cariotipo y/o QF-PCR. El conjunto presenta un marcado desbalance de clases, con una prevalencia observada del 5%.

Las variables disponibles incluyen características maternas (edad, talla y peso), así como mediciones ecográficas y bioquímicas obtenidas durante el primer y segundo trimestre del embarazo. En el primer trimestre se dispone de la edad gestacional (EG) en días de la medición, niveles de PAPP-A, β -hCG libre, longitud cefalocaudal (CRL) y translucencia nuchal (sn). En el segundo trimestre se incluyen la EG en días de la medición, diámetro biparietal (DBP), perímetro cefálico, perímetro abdominal y longitud femoral. Adicionalmente, se recogen variables indicadoras de signos ecográficos de alarma en el segundo trimestre como: espesor nuchal aumentado (mEN), arteria umbilical única (mAUU), pielectasia renal bilateral (mPRB), intestino hiperecogénico (mIHE), ventriculomegalia cerebral (mvvll), cardiopatía congénita (mCOR), anomalía digestiva (mDIG) u otras anomalías estructurales ligadas a cromosomopatías (mOTR).

El tratamiento de los datos se ha regido estrictamente por el marco legal y conforme a la normativa vigente en materia de protección de datos (RGPD y LOPDGDD). La información fue proporcionada en formato anonimizado o seudonimizado, y su uso se ha limitado exclusivamente a los fines de esta investigación. Por tanto, el acceso a los datos está restringido y sujeto a acuerdos de confidencialidad con las entidades proveedoras.

3.2. Preprocesado de los datos

El preprocesado se llevó a cabo en distintas etapas con el objetivo de garantizar la calidad de la información, la coherencia estructural y la adecuación de las variables para el entrenamiento de los modelos predictivos.

1. Limpieza inicial

Dado que el presente estudio no tiene como objetivo un análisis longitudinal, fue necesario consolidar correctamente las observaciones correspondientes a un mismo embarazo. Para ello, se construyeron tres subconjuntos de datos: (a) un conjunto de variables maternas, que incluye la presencia de SD (clase), edad, talla y peso, con un único identificador por embarazo; (b) un conjunto de variables del primer trimestre, conservando el identificador del embarazo y la edad gestacional (EG); y (c) un conjunto de variables del segundo trimestre, inicialmente con posibilidad de múltiples registros por embarazo.

La variable edad materna presentó un porcentaje reducido de valores ausentes (0.15%) que se imputaron mediante la mediana de la muestra (33.2 años). En el mismo

subconjunto, las variables de talla y peso presentaron aproximadamente un 20% de valores faltantes, por lo que su imputación se realiza mediante el algoritmo de *k-nearest neighbors* (kNN), ajustado exclusivamente sobre el conjunto de entrenamiento y posteriormente aplicado al conjunto de test, así evitando fuga de información.

En el subconjunto correspondiente al segundo trimestre, se detectó que algunos embarazos disponían de múltiples registros ecográficos. Para garantizar una única observación por embarazo, se seleccionó un único registro siguiendo un criterio jerárquico: se prioriza el registro con menor número de valores ausentes y, en caso de empate, aquel cuya EG se encuentre más próxima a la semana 20 de gestación, cuantificando dicha proximidad mediante distancia euclídea. Esta decisión se fundamenta en que la guía de la *International Society of Ultrasound in Obstetrics and Gynecology* (ISUOG) recomienda realizar la exploración morfológica entre las semanas 18 y 22 de gestación [17].

Tras comprimir los registros múltiples en el segundo trimestre, únicamente se identificaron tres registros con algún valor faltante residual, que fueron eliminados.

Finalmente, la distribución definitiva de registros disponibles (Figura 1) fue la siguiente: 139 casos afectos, de los cuales 78 disponían de información completa en ambos trimestres, 22 únicamente del primer trimestre y 39 únicamente del segundo trimestre. En el grupo control se dispuso de 2599 embarazos, con 1958 registros completos, 641 únicamente del primer trimestre y ningún caso con información exclusiva del segundo trimestre.




Figura 1 Diagrama de Venn

2. Partición de entrenamiento y test

Debido a la reducida prevalencia observada (5%), se optó por no reservar un conjunto independiente de validación, ya que ello habría reducido aún más la muestra utilizable para el entrenamiento. En su lugar, el ajuste de hiper parámetros y la evaluación interna de los modelos se realizaron mediante validación cruzada sobre el conjunto de entrenamiento.

Para la evaluación final del rendimiento, se reserva un conjunto de prueba externo compuesto del 20% de las muestras completas, seleccionado mediante partición estratificada para preservar la proporción de la clase. Como resultado el conjunto de pruebas quedó 392 controles y 16 casos afectos, mientras que el 80% restante, igualmente estratificado, se destina al entrenamiento y validación cruzada de los modelos.

3. Múltiplos de la Mediana (MoM).

Esta técnica de transformación expresa cada medición como el cociente entre el valor observado y la mediana esperada para un embarazo comparable, permitiendo reducir la variabilidad debida a factores fisiológicos y mejorar la comparabilidad entre individuos.

El uso de valores MoM adquiere una importante relevancia en un contexto de cribado prenatal, donde muchas variables dependen fuertemente de la edad gestacional y, en algunos casos, de otros parámetros fetales como la longitud cráneo-rabadilla (CRL). En particular, la mediana de referencia se estimó en función de la EG para la mayoría de las variables y en función del CRL para la translucencia nuchal, siguiendo la práctica habitual en medicina fetal.

Bajo el supuesto habitual de que ciertas mediciones prenatales presentan una distribución aproximadamente log-normal, la transformación logarítmica de los valores MoM permite recentrar las distribuciones respecto a cero:

$$\begin{aligned} \ln X &\sim N(\mu, \sigma) && \rightarrow E(X) = e^\mu \\ \ln X - \mu &= \ln \frac{X}{e^\mu} = \ln MoM \sim N(0, \sigma) \end{aligned} \quad (1)$$

De este modo, la transformación facilita tanto la comparación entre distintas etapas de la gestación como la modelización estadística posterior.

Idealmente, las medianas de referencia deberían estimarse a partir de tablas ajustadas sobre la propia población de estudio. No obstante, dado el tamaño muestral disponible y la limitada densidad de observaciones a lo largo del rango gestacional, se optó por emplear estándares internacionales previamente validados, concretamente desarrollados por INTERGROWTH-21st Project y The Fetal Medicine Foundation [12,13,18].

4. Corrección por peso

En el marco del cribado prenatal del primer trimestre, es una práctica habitual corregir las variables séricas en función del peso materno, dado que existe evidencia de un efecto de hemodilución asociado al aumento del volumen plasmático en gestantes con mayor peso corporal. Como resultado directo, concentraciones séricas como la PAPP-A y HCG muestran una dependencia sistemática respecto al peso materno, que debe corregirse para mejorar la comparabilidad entre pacientes [19,20].

Específicamente, se ha ajustado una regresión log-lineal con el peso materno (2), y este explica aproximadamente un 9.4% de la variabilidad observada en PAPP-A y un 5.3% en HCG. Justificando así su incorporación en el ajuste de los valores log MoM.

$$\begin{aligned} PAPP_{LMoM}^* &= PAPP_{LMoM} - (4.14 - 0.99 \cdot \ln PESO) \\ HCG_{LMoM}^* &= HCG_{LMoM} - (3.3 - 0.8 \cdot \ln PESO) \end{aligned} \quad (2)$$




Figura 2 Corrección de PAPP-A y HCG según peso

5. Detección y tratamiento de valores extremos

La identificación de valores extremos se realizó mediante el estadístico robusto mediana de las desviaciones absolutas a la mediana (*Mean Absolute Deviation, MAD*), definido en (3).

$$MAD = Med(|x_i - Med(x)|) \quad (3)$$

El MAD constituye una medida robusta de dispersión, al ser poco sensible a observaciones extremas y no depender estrictamente del cumplimiento de supuestos distribucionales, en contraste con la desviación estándar.

$$\hat{\sigma} = \frac{MAD}{\phi^{-1}(0.75)} \approx 1.4826 \cdot MAD \quad (4)$$

Bajo el supuesto de distribución aproximadamente normal, el MAD puede escalarse para obtener un estimador consistente de la desviación estándar poblacional (4). Donde $\phi^{-1}(0.75)$ corresponde al percentil 75 de la distribución normal estándar [21]. Posteriormente, se definen los límites de truncamiento como: $Med(x) \pm 3.5 \cdot \hat{\sigma}$. Este criterio permite conservar aproximadamente el 99.98% de las observaciones bajo normalidad, de modo que únicamente se truncaron los valores más extremos alejados del patrón de distribución esperado.

Tabla 1: Intervalos de truncamiento según MAD

Variable	Límite inferior	Límite superior
PAPP-A	-2.033	2.027
HCG	-2.251	2.252
SN	-0.998	0.781
DBP	-0.185	0.173
Perímetro cefálico	-0.145	0.169
Perímetro abdominal	-0.213	0.183
Longitud femoral	-0.17	0.212

6. Análisis exploratorio

En esta fase se exploraron las distribuciones marginales de las variables según clase, con el objetivo de evaluar su capacidad discriminativa entre casos y controles. Para complementar la inspección visual, se calculó una versión del área bajo la curva ROC (5), que en este contexto puede interpretarse como la capacidad de una variable para ordenar correctamente casos y controles.

$$AUC = \max\{P(X_{caso} > X_{control}), P(X_{caso} < X_{control})\} \quad (5)$$

De este modo, valores mayores que 0.5 indican mayor separabilidad entre clases, independientemente del sentido de la asociación.

La distribución y correlación de variables se encuentran en la sección de resultados, 4.1.

3.3. Diseño experimental y particionados

El flujo metodológico desarrollado en este trabajo se compone de las siguientes etapas:

- Construcción de tres escenarios predictivos independientes (T1, T2 y T1+T2).
- Evaluación preliminar del impacto de técnicas de muestreo para tratamiento del desbalance de clases.
- Comparación sistemática de seis familias de clasificadores bajo validación cruzada anidada y calibración probabilística.
- Selección de modelos mediante optimización multiobjetivo priorizando TPR5.
- Construcción y evaluación final de estrategias de ensamble frente al mejor modelo conjunto sobre un conjunto TEST externo.

El diseño experimental se estructuró en tres escenarios predictivos principales: variables de primer trimestre (T1), variables del segundo trimestre (T2) e integración conjunta de ambos trimestres (T1+T2), incorporando en todos los casos las covariables maternas disponibles. Adicionalmente, se reservó un conjunto de prueba externo (TEST) para la comparación final entre modelos. La variable objetivo (CLASE) se excluyó de los predictores, definiéndose para cada escenario una matriz de características “X” y vector respuesta “y”.

Muestreo

Como fase preliminar, se realizó una comparación exploratoria de técnicas de muestreo sobre el bloque T1 con el objetivo de evaluar si el tratamiento explícito del desbalance de clases aportaba mejoras predictivas. Se exploraron técnicas como *Synthetic Minority Over-sampling Technique* (SMOTE) [22], *Adaptive Synthetic Sampling* (ADASYN) [23] y la combinación híbrida SMOTE con *Edited Nearest Neighbours* [24] (SMOTEENN).

Las técnicas de sobre-muestreo como SMOTE y ADASYN generan nuevas muestras por interpolación, la diferencia entre ambas es que ADASYN las genera cerca de observaciones “difíciles” que han sido mal clasificadas usando k-NN, mientras que SMOTE no hace esta distinción. La técnica de submuestreo ENN elimina las muestras de la clase mayoritaria en cuyo vecindario predomine otra clase.

La comprobación se realizó con dos clasificadores: Naive Bayes y SVC:




Figura 3 Gráficos de barras comparativos sobre las técnicas de muestreo

Dado que estas estrategias no aportaron mejoras consistentes respecto a los modelos base, el análisis principal posterior se desarrolló sin muestreo adicional.

Junto a ello, se construyó adicionalmente una versión escalada de las variables numéricas maternas (edad, talla y peso), con el objeto de homogenizar magnitudes y facilitar el ajuste de modelos sensibles a escala.

Esquema de validación y calibración

Para la evaluación del rendimiento predictivo se empleó un esquema de validación cruzada anidada y estratificada. La validación externa se implementó mediante validación cruzada estratificada de 5 particiones, preservando en cada partición la proporción original entre casos y controles.

La estratificación resulta especialmente útil en problemas de clasificación desbalanceada, ya que reduce el riesgo de generar particiones sin observaciones de la clase minoritaria, situación que impediría calcular determinadas métricas de rendimiento o produciría estimaciones altamente inestables. Desde un punto de vista práctico, este procedimiento garantiza una distribución más homogénea de casos entre folds y mejora la comparabilidad entre iteraciones. No obstante, la estratificación constituye principalmente una solución de carácter técnico y computacional, más que estadístico. Al forzar particiones más equilibradas se reduce artificialmente la variabilidad observada entre folds, de modo que la dispersión de métricas ya no refleja correctamente la incertidumbre real asociada al entrenamiento de clasificadores en presencia de eventos raros y tamaños muestrales limitados [25].

Dentro de cada partición externa, el ajuste de hiper parámetros se realizó mediante una validación interna anidada usando validación cruzada estratificada de 3 particiones. Una vez seleccionados los hiper parámetros óptimos, el modelo se recalibró sobre el conjunto de entrenamiento del fold externo utilizando *CalibratedClassifiedCV* con método sigmoide y validación cruzada estratificada repetida de 3 particiones y 5 repeticiones.

Este procedimiento define un flujo completo de validación cruzada anidada compuesto por: (a) estimación externa del rendimiento generalizable, (b) optimización interna de hiper parámetros, (c) calibración posterior de probabilidades y (d) evaluación final sobre el subconjunto externo de test del fold. De este modo, el conjunto de evaluación externo no participa en ninguna fase de ajuste ni calibración, reduciendo el riesgo de sesgo optimista y fuga de información.

Modelos evaluados

En cada uno de los escenarios T1, T2 y T1+T2 se compararon seis familias de clasificadores: regresión logística, *K- nearest neighbours* (KNN), *Gaussian Naive Bayes* (NB), análisis discriminante cuadrático (QDA), clasificador de vectores soporte (SVC) y bosque aleatorio (RF).

a. Regresión logística

Es un modelo lineal que utiliza la función logística (sigmoide) para mapear una combinación lineal de las variables en una probabilidad entre 0 y 1.

Sirve como línea de base fundamental. Es altamente interpretable, lo que permite ver el peso directo de cada biomarcador.

b. KNN

Es un algoritmo no paramétrico basado en la instancia que clasifica una muestra según la clase mayoritaria de sus “k” vecinos más cercanos en el espacio de características, utilizando métricas de distancia.

Permite capturar patrones locales sin asumir una distribución global de los datos, es sensible al ruido y al desbalance.

c. NB

Basado en el teorema de Bayes, asume que las variables predictoras son independientes entre sí y siguen una distribución normal.

Es extremadamente rápido y eficiente. En medicina, se usa a menudo porque se asemeja a los modelos clásicos de razón de verosimilitud, lo que permite comparar el enfoque de ML con la estadística Bayesiana tradicional.

d. QDA

A diferencia del análisis lineal, asume que cada clase tiene su propia matriz de covarianza, lo que genera fronteras de decisión cuadráticas (curvas).

Es adecuado cuando se sospecha que la relación entre biomarcadores en fetos afectados es distinta a la de los controles, permitiendo modelar interacciones no lineales sencillas.

e. SVC

Busca el hiperplano que maximiza el margen entre las clases. Utiliza el “truco del kernel” para proyectar los datos a dimensiones superiores donde sean linealmente separables.

Es muy eficaz en espacios de alta dimensión y robusto frente al sobreajuste.

f. RF

Es un método de ensamble que combina múltiples árboles de decisión entrenados en subconjuntos de datos (bagging) y variables.

Es excelente para capturar relaciones complejas y no lineales.

La inclusión de estos modelos permite comparar aproximaciones lineales, probabilísticas, basadas en distancia, discriminantes, basadas en márgenes y ensamblados de árboles dentro de un mismo protocolo experimental.

Optimización de hiper parámetros

La optimización de hiper parámetros se realizó mediante *Optuna* [26] con 50 iteraciones por estudio. Dado que el problema se formuló como optimización multiobjetivo, se empleó NSGA-II para aproximar el frente de Pareto, seleccionando posteriormente la solución final mediante estrategia TOPSIS [27].

Esta optimización se basó en predicciones *out-of-fold* (OOF) generadas durante la validación interna, en lugar de utilizar rendimiento sobre modelos reentrenados en el conjunto completo de entrenamiento. Esta estrategia proporciona una estimación más estable del rendimiento esperado y reduce el riesgo de sobreajuste durante la selección de hiper parámetros.

Ensamble y comparación final

Tras la comparación independiente de los escenarios, se seleccionaron los mejores clasificadores de T1 y de T2 para construir un modelo de *stacking*. Para ello, se recuperaron predicciones OOF generadas durante la validación cruzada de ambos modelos base, utilizándose como meta-características de entrada para un metamodelo de regresión logística.

Se evaluaron dos configuraciones: (a) un modelo de *stacking* estándar, construido exclusivamente a partir de las probabilidades OOF de T1 y T2, y (b) una variante con *passthrough*, en la que además se reincorporaron las variables originales al metamodelo. Esta comparación permite evaluar si la combinación de scores es suficiente y resume adecuadamente la información predictiva o si persiste valor incremental al conservar también los predictores originales.

La comparación final entre estrategias se realizó exclusivamente sobre el conjunto TEST externo, evaluando tres alternativas: el modelo de *stacking* estándar, el modelo de *stacking* con *passthrough* y el mejor modelo directo entrenado sobre T1+T2.

3.4. Calibración de probabilidades

En problemas de clasificación clínica, las probabilidades predichas por algunos modelos no reflejan adecuadamente la frecuencia real del evento, lo que limita su interpretación directa como estimadores de riesgo. La calibración permite corregir este desajuste, aproximando la probabilidad predicha a la probabilidad observada y facilitando así una interpretación más fiable de la salida del modelo.

En este trabajo, las probabilidades se calibraron mediante el escalado de Platt, implementado a través de *CalibratedClassifierCV* con método sigmoide. Este procedimiento se ajusta a una transformación logística sobre las puntuaciones originales del clasificador, corrigiendo sistemáticamente desviaciones de calibración mediante una función sigmoide [28].

La elección de este método se fundamentó en el reducido tamaño muestral disponible dentro de cada fold. Aunque el escalado sigmoide asume una estructura de error relativamente regular y puede resultar menos flexible en contextos fuertemente desbalanceados o con errores de calibración asimétricos [29], presenta menor riesgo de sobreajuste que alternativas no paramétricas como la regresión isotónica, especialmente cuando el número de observaciones es limitado.

Para evaluar visualmente el efecto de la calibración, en la sección de resultados se incluyen curvas de calibración [30], representaciones del mapeo entre probabilidades no calibradas y calibradas, así como distribuciones de densidad de la clase real respecto a la probabilidad calibrada mediante KDE, acompañadas de la curva del logaritmo del cociente de verosimilitudes positivas (log LR+). Además, en las propias ilustraciones se evalúa la bondad de calibración mediante el estadístico Z de Spiegelhalter, descrito más adelante (Figura 8, Figura 12 y Figura 17).

Umbral:

Dado que el objetivo final del modelo es su aplicación en un contexto de cribado prenatal, no se utilizó un umbral fijo de clasificación de 0.5. En su lugar, se estimó exclusivamente sobre el conjunto de entrenamiento un umbral asociado a una tasa de falsos positivos del 5%, y aplicándose posteriormente de forma fija sobre el conjunto de evaluación externo.

Esta estrategia permite adaptar la decisión binaria a un contexto clínico donde resulta prioritario maximizar sensibilidad bajo una restricción estricta de falsos positivos, reproduciendo el escenario operativo real del cribado prenatal.

3.5. Métricas de evaluación

La evaluación del rendimiento se estructuró en tres grupos de métricas: métricas de clasificación binaria, métricas de calibración y métricas de *ranking* o discriminación.

Las métricas de clasificación binaria se calcularon a partir de las predicciones obtenidas tras aplicar el umbral de decisión descrito previamente, ajustado para mantener una tasa de falsos positivos esperada del 5%. Estas predicciones pueden resumirse mediante la matriz de confusión, compuesta por verdaderos positivos (TP), falsos positivos (FP), verdaderos negativos (TN) y falsos negativos (FN).

La **sensibilidad** cuantifica la capacidad del modelo para identificar correctamente la clase positiva, es decir, de minimizar la proporción de falsos negativos y se define como

$$Sens = \frac{TP}{TP + FN} \quad (6)$$

De forma complementaria, la **especificidad** mide la capacidad para identificar correctamente la clase negativa, minimizando la aparición de falsos positivos y se define como

$$Spec = \frac{TN}{TN + FP} \quad (7)$$

Dado el ajuste explícito del umbral a un régimen de bajos falsos positivos y la naturaleza desbalanceada del problema, se espera una especificidad elevada y relativamente estable entre modelos. En consecuencia, la sensibilidad adquiere un papel más relevante como indicador del rendimiento sobre la clase minoritaria.

Con objetivo de resumir conjuntamente ambas dimensiones, se considera adicionalmente la **media geométrica** entre sensibilidad y especificidad, definida como

$$G\ mean = \sqrt{Sens \cdot Spec} \quad (8)$$

Esta métrica penaliza de forma no lineal valores bajos en cualquiera de sus componentes, evitando que un rendimiento aparentemente elevado en especificidad oculte deficiencias importantes en sensibilidad.

Además del rendimiento discriminativo, se evaluó la capacidad de los modelos para producir probabilidades consistentes con la frecuencia observada del evento.

Para ello se consideró el **Brier Score** (BS) definido como el error cuadrático medio entre la respuesta observada (y) y la probabilidad predicha (p) (9). Esta métrica puede descomponerse en dos términos asociado al error de calibración (C) y a la distribución de probabilidades predichas (S).

$$\begin{aligned} BS &= \frac{1}{n} \sum_{i=1}^n (y_i - p_i)^2 \\ &= C + S \\ &= \frac{1}{n} \sum_{i=1}^n (y_i - p_i)(1 - 2p_i) + \frac{1}{n} \sum_{i=1}^n p_i(1 - p_i) \end{aligned} \quad (9)$$

Bajo la hipótesis nula de calibración perfecta ($E[y_i] = p_i \forall i$), el error C esperado es nulo, de modo que el valor esperado de BS queda determinado por el segundo término S.

A partir de esta propiedad se define el estadístico **Z de Spiegelhalter** [31], que cuantifica de forma estandarizada la desviación del BS observado respecto a su esperanza bajo calibración perfecta.

$$Z = \frac{BS - E[BS]}{\sqrt{Var(BS)}} = \frac{\sum_{i=1}^n (y_i - p_i)(1 - 2p_i)}{\sqrt{\sum_{i=1}^n p_i(1 - p_i)(1 - 2p_i)^2}} \quad (10)$$

Este estadístico sigue asintóticamente una distribución normal estándar, por lo que un p-valor bilateral inferior al nivel de significación prefijado (0.05) proporciona evidencia de falta de calibración.

A diferencia de otros procedimientos como el test de Hosmer-Lemeshow, el estadístico de Spiegelhalter no requiere de agrupar previamente observaciones en intervalos de riesgo, evitando así una discretización potencialmente inestable en muestras limitadas o clases raras.

De forma complementaria se consideró el **Brier score ponderado** (WBS), una variante que ajusta la contribución de cada observación según la frecuencia relativa de su clase, otorgado mayor peso a errores cometidos sobre la clase minoritaria.

$$WBS(p) = \frac{\sum_i w(y_i)(y_i - p_i)^2}{\sum_i w(y_i)} \quad (11)$$

$$w(y_i) = \frac{y_i}{\bar{y}} + \frac{1 - y_i}{1 - \bar{y}} \quad \forall y_i \in \{0,1\}$$

Esta ponderación resulta especialmente útil en contextos de cribado y clasificación desbalanceada, donde un error sobre la clase positiva presenta mayor relevancia clínica y metodológica que un error equivalente sobre la clase mayoritaria.

Si queremos cuantificar la mejora del clasificador con respecto una referencia aleatoria, podemos integrar una **puntuación de habilidad de Brier ponderada** (WBSS), definida como:

$$WBSS = 1 - \frac{WBS(p)}{WBS(\bar{y})} \quad (12)$$

Donde el caso ideal corresponde a WBSS=1, el caso donde aporta lo mismo que la referencia es WBSS=0, y si es peor que la referencia WBSS<0.

Por último, se consideraron métricas orientadas a evaluar la capacidad del modelo para ordenar correctamente las observaciones según su riesgo estimado.

$$P = \frac{TP}{TP + FP} \quad (13)$$

La precisión se define en (13) y cuantifica la proporción de predicciones positivas que corresponden realmente a la clase positiva. A partir de esta métrica puede construirse la curva precisión-sensibilidad, que describe el equilibrio entre estas métricas a lo largo de distintos umbrales de decisión.

En problemas desbalanceados, esta representación resulta especialmente informativa, ya que una elevada área bajo la curva refleja simultáneamente baja proporción de falsos positivos y buena capacidad de recuperación de casos positivos.

La **precisión media** (AP) resume dicha curva mediante una media ponderada de la precisión en cada nivel de sensibilidad:

$$AP = \sum_n (Sens_n - Sens_{n-1})P_n \quad (14)$$

Adicionalmente, la métrica prioritaria del estudio fue **TPR@5%FPR** (tpr5), definida como la sensibilidad alcanzada al fijar una tasa de falsos positivos del 5%. Esta métrica se alinea directamente con el objetivo clínico del cribado prenatal, donde resulta prioritario maximizar la detección de casos manteniendo un nivel estrictamente controlado de falsos positivos.

A diferencias de métricas globales como AUROC, que integra el rendimiento sobre todo el rango de umbrales, tpr5 concentra la evaluación en una región operativamente relevante en la curva ROC, proporcionando una medida más interpretable y útil para comparar clasificadores bajo restricciones clínicas realistas.

3.6. Implementación

Toda la implementación se desarrolló en Python 3.13.9 mediante cuadernos Jupyter, quedan adjuntos los archivos utilizados en el anexo.

Tabla 2 Librerías utilizadas

Librería	Versión	Uso principal
numpy	2.4.6	Cálculo numérico
pandas	3.0.3	Carga de datos, manejo de DataFrame y tablas de resultados
matplotlib	3.10.9	Gráficas base
seaborn	0.13.2	Visualización complementaria de kdeplot, rugplot y boxplot
scipy	1.17.1	Preprocesado y análisis estadístico
statsmodels	0.14.6	Diagnóstico estadístico
scikit-learn (sklearn)	1.8.0	Validación cruzada, escalado, calibración, métricas y clasificadores
Imbalanced-learn (imblearn)	0.14.0	Comparación de muestreos, métricas y pipes
optuna	4.8.0	Optimización de hiperparámetros y selección multiobjetivo por frente Pareto
calzone	1.2.0	Evaluación de calibración
joblib	1.5.2	Guardado de los modelos
tqdm	4.67.1	Barras de progreso en el cuaderno
Shap	0.51.0	Shapley Additive explanations
PyALE	1.2.0	Accumulated local effects

3.7. Interpretabilidad

Con el objetivo de complementar la evaluación cuantitativa del rendimiento, se incorporaron métodos de interpretabilidad global orientados a caracterizar la contribución y efecto funcional de las variables sobre las predicciones generadas por los modelos seleccionados.

Siguiendo la taxonomía de interpretabilidad propuesta por Doshi-Velez y Kim [32], se adopta un enfoque “*functionally-grounded*”, dado que el objetivo no consiste en evaluar la utilidad explicativa en tareas clínicas reales ni mediante estudios con usuarios, sino caracterizar el comportamiento interno y la influencia de los predictores sobre las salidas del modelo mediante métodos post hoc de interpretación global.

Dado que el presente trabajo se centra en la comparación metodológica de clasificadores y no en experimentación con usuarios, la interpretabilidad se abordó principalmente desde un enfoque funcional y global.

Para ello se emplearon gráficos de **efectos locales acumulados** (*Accumulated Local Effects*, ALE) [33], utilizados para analizar el efecto marginal de variables individuales sobre la predicción media del modelo. A diferencia de los gráficos de dependencia parcial (PDP), los gráficos ALE estiman efectos locales mediante diferencias acumuladas condicionadas, lo que reduce el sesgo inducido por correlación entre predictores y evita evaluar combinaciones de variables poco plausibles empíricamente.

Los gráficos ALE se centraron en cero, de modo que cada valor representa una desviación relativa respecto a la predicción media global. Adicionalmente se consideraron representaciones bidimensionales para explorar posibles interacciones entre pares de variables, dado que en ausencia de interacción el efecto conjunto debería aproximarse a una superficie nula para covariables no correladas.

Adicionalmente, se calcularon explicaciones basadas en **Shapley Additive explanations** (SHAP) [34], fundamentadas en teoría de juegos cooperativos. Este método permite descomponer la predicción individual de cada observación como suma aditiva de contribuciones atribuibles a cada característica. Para obtener interpretabilidad global, se agregaron los valores SHAP individuales sobre todas las observaciones, resumiendo la relevancia de cada variable mediante la media del valor absoluto de sus contribuciones. Finalmente, se combinan simultáneamente las magnitudes de importancia y dirección del efecto de cada predictor sobre la salida del modelo.

4. Resultados

Se presentan los resultados del análisis exploratorio

4.1. Análisis exploratorio

Las variables con mayor capacidad discriminativa fueron la edad materna (AUC = 0.72), PAPP-A (AUC = 0.86), HCG (AUC = 0.71), SN (AUC = 0.81), perímetro cefálico (AUC = 0.74) y la longitud femoral (LF; AUC = 0.83).




Figura 4 Distribución de variables

Adicionalmente, se analizaron las correlaciones entre variables de primer y segundo trimestre por separado, así como su relación con la variable respuesta.




Figura 5 Matriz de correlación del primer trimestre




Figura 6 Matriz de correlación del segundo trimestre

Dado que las variables continuas fueron transformadas al logaritmo de los MoM, las correlaciones observadas deben interpretarse sobre dichas variables normalizadas.

En las variables del primer trimestre no se identificaron asociaciones especialmente relevantes más allá de la correlación esperable entre peso y talla materna ($r = 0.3$). Del mismo modo, la ausencia de correlación relevante entre peso materno y marcadores séricos tras la corrección confirma que el ajuste por peso (2) eliminó adecuadamente esta fuente de variabilidad.

En el segundo trimestre se observó una correlación fuerte entre perímetro cefálico y diámetro biparietal ($r = 0.82$), consistente con que ambas variables describen dimensiones complementarias de la morfología craneal fetal. Las biometrías ecográficas (diámetro biparietal, perímetro cefálico, perímetro abdominal y longitud femoral) presentaron correlaciones moderadas entre sí ($r \in [0.47, 0.54]$), reflejando la coherencia esperable entre medidas de crecimiento fetal. Estas biometrías mostraron correlaciones débiles con el peso materno, sugiriendo una dependencia limitada tras la estandarización por EG y transformación a MoM.

Respecto a los marcadores de alerta, se observó correlación positiva entre cardiopatía congénita (mCOR) y anomalías digestivas (mDIG) ($r = 0.32$), así como entre la cardiopatía congénita y otras anomalías estructurales (mOTR) ($r = 0.35$).

En relación con la variable respuesta, y de forma consistente con las distribuciones observadas (Figura 4), la clase presentó correlación negativa con PAPP-A ($r = -0.27$) y positiva con la translucencia nucal ($r = 0.30$). Por su parte, la mayoría de las biometrías del segundo trimestre correlacionaron negativamente con la clase ($r \in [-0.35, -0.22]$) excepto con el perímetro abdominal, que no mostró asociación relevante.

Estos resultados son coherentes con hallazgos clínicos como el acortamiento de huesos largos, especialmente el fémur y húmero, que constituye un rasgo fenotípico característico del SD [35]. Otro rasgo es la braquicefalia, definida como un cráneo relativamente más ancho y corto, que se ha asociado a incrementos relativos en diámetro biparietal y perímetro cefálico [36]. También resulta relevante la correlación positiva de la clase con el marcador de cardiopatía congénita ($r = 0.34$) o con otras anomalías estructurales ($r = 0.28$), esto es coherente con la elevada prevalencia de cardiopatías congénitas descrita en fetos con SD, cercana al 40% [37].

Dada la ausencia de asociación entre perímetro abdominal y la clase, se exploró adicionalmente su uso como variable de referencia para construir variables derivadas, calculando ratios o diferencias logarítmicas respecto al resto de biometrías. Sin embargo, estas transformaciones no mejoraron la capacidad discriminativa marginalmente. Por ejemplo, la razón entre longitud femoral y perímetro abdominal mostró una correlación inferior a la de la longitud femoral con la clase ($r = -0.26$ frente a $r = -0.35$).

A continuación, se presentan los resultados organizados en tres escenarios experimentales.

4.2. Escenario del primer trimestre

En el escenario del primer trimestre, el modelo seleccionado fue SVC, al obtener el mejor equilibrio global entre discriminación, calibración y estabilidad. En particular, alcanzó un tpr5 de 0.83, una precisión media (AP) de 0.67 y un Brier Skill Score ponderado de 0.53, superando ligeramente a la regresión logística y posicionándose como el clasificador más robusto en este escenario.




Figura 7 Comparación de modelos en 1T

Tabla 3 Métricas OOF en 1T

	Sensibilidad	Especificidad	G mean	Tpr5	WBSS	AP
SVC «	0.81 ± 0.05	0.95 ± 0.01	0.88 ± 0.03	0.83 ± 0.06	0.53 ± 0.05	0.67 ± 0.06
Log reg	0.81 ± 0.07	0.95 ± 0.04	0.88 ± 0.04	0.82 ± 0.08	0.53 ± 0.06	0.66 ± 0.07
QDA	0.83 ± 0.09	0.95 ± 0.01	0.89 ± 0.05	0.82 ± 0.08	0.50 ± 0.07	0.65 ± 0.09
NB	0.81 ± 0.05	0.95 ± 0.01	0.88 ± 0.03	0.80 ± 0.07	0.48 ± 0.07	0.65 ± 0.08
RF	0.69 ± 0.13	0.97 ± 0.02	0.81 ± 0.07	0.79 ± 0.07	0.48 ± 0.12	0.64 ± 0.07
KNN	0.38 ± 0.20	0.99 ± 0.01	0.59 ± 0.17	0.68 ± 0.12	0.37 ± 0.18	0.53 ± 0.16

Los modelos SVC, regresión logística y QDA muestran un rendimiento global muy similar. No obstante, SVC presenta un rendimiento ligeramente superior y una menor variabilidad entre folds, y aunque la regresión logística constituye una alternativa potencialmente más interpretable, la selección final priorizó SVC por el criterio TOPSIS considerando las variables tpr5, WBSS y AP.

Como comprobación adicional, y dado que la elección de SVC implica sacrificar interpretabilidad intrínseca respecto a la regresión logística, se evaluó específicamente la calidad de sus probabilidades calibradas. A continuación, se muestran las gráficas de calibración:




Figura 8 Calibración de SVC en 1T

El modelo SVC presenta una calibración robusta, como se observa en la alineación de la curva de calibración (Figura 8 izquierda) con la diagonal y un mapeo (Figura 8 centro) de probabilidades cercano a la identidad. Estadísticamente, esto se respalda con el test de Spiegelhalter ($Z = -1.263$), cuyo resultado no permite rechazar la hipótesis nula de una correcta calibración.

En cuanto a la distribución de probabilidades (Figura 8 derecha), se evidencia una excelente capacidad de identificación de la clase control, con una densidad fuertemente concentrada en el entorno de cero. Por el contrario, la clase SD muestra una mayor dispersión, comportamiento ya sugerido por los diagramas de caja marginales. Esto indica que, si bien el modelo es altamente específico, la asignación de riesgo en la clase minoritaria es susceptible. Finalmente, la curva log LR+ monótona creciente valida la utilidad clínica del modelo para el cribado, confirmando que incrementos en la probabilidad predicha se traducen efectivamente en un aumento del riesgo relativo, a pesar de que la separación entre los perfiles de riesgo alto sea gradual.

A continuación, se muestran el gráfico SHAP (Figura 9) que muestra cuánto contribuye cada variable a la predicción final.




Figura 9 SHAP resumen de SVC en 1T




Figura 10 Efectos ALE de SVC en 1T

El análisis SHAP indica que la variable más influyente es PAPP-A, seguida de la translucencia nual (sn), HCG y la edad materna. Valores menores de PAPP-A que la mediana esperada para la edad gestacional se asocia a mayor riesgo. Por el contrario, valores más altos que la mediana esperada para la edad gestacional o CRL en sn y HCG respectivamente, se asocian a mayor riesgo. Con respecto a la edad materna, edades por encima de 37 años aumentan el riesgo de SD.

4.3. Escenario del segundo trimestre

En el escenario del segundo trimestre, el modelo seleccionado fue Random Forest, al obtener el mejor compromiso entre capacidad discriminativa y calibración probabilística dentro de este bloque. En particular, alcanzó un tpr5 de 0.77, una precisión media de 0.68 y un Brier Skill Score ponderado de 0.5.




Figura 11 Comparación de modelos en el 2T

Tabla 4 Métricas OOF en el 2T

	Sensibilidad	Especificidad	G mean	Tpr5	WBSS	AP
RF «	0.59 ± 0.21	0.97 ± 0.03	0.75 ± 0.13	0.77 ± 0.06	0.50 ± 0.12	0.68 ± 0.07
log reg	0.65 ± 0.10	0.95 ± 0.01	0.79 ± 0.05	0.65 ± 0.10	0.43 ± 0.12	0.62 ± 0.07
SVC	0.60 ± 0.13	0.95 ± 0.02	0.75 ± 0.08	0.56 ± 0.09	0.28 ± 0.11	0.53 ± 0.07
QDA	0.54 ± 0.13	0.95 ± 0.02	0.71 ± 0.08	0.43 ± 0.10	0.23 ± 0.08	0.47 ± 0.04
NB	0.55 ± 0.18	0.95 ± 0.02	0.72 ± 0.11	0.51 ± 0.07	0.20 ± 0.06	0.42 ± 0.03
KNN	0.10 ± 0.04	1.00 ± 0.00	0.31 ± 0.06	0.34 ± 0.08	0.17 ± 0.03	0.35 ± 0.06

El Random Forest supera al resto de modelos, sugiriendo que las relaciones no lineales en variables ecográficas son relevantes. Sin embargo, presenta mayor variabilidad en sensibilidad debido a su estructura basada en árboles.




Figura 12 Calibración de RF en 2T

La curva de calibración del modelo RF (Figura 12) está sistemáticamente por encima de la diagonal, indicando una tendencia inicial a sobrestimar el riesgo. Tras la calibración, se observa una corrección heterogénea de probabilidades, reduciendo probabilidades bajas y aumentando probabilidades elevadas. Pese a esta corrección menos homogénea que en el primer trimestre, el modelo puede considerarse adecuadamente calibrado según el test de Spiegelhalter ($Z = -0.816$).

La distribución de probabilidades entre las clases es similar al primer trimestre y la curva de log LR+ crece de forma constante pero suave. Con respecto a las métricas, el segundo trimestre es menos diagnosticable ($tpr5 = 0.77$) que el primer trimestre ($tpr5 = 0.83$).




Figura 13 SHAP resumen de RF en 2T




Figura 14 Efectos ALE de RF en 2T

Según los valores de SHAP (Figura 13), la longitud del fémur (LF) y el perímetro cefálico son las variables con mayor contribución al riesgo predicho. Valores bajos de LF y perímetro cefálico respecto a la mediana esperada para la edad gestacional se asocian a un incremento en el riesgo predicho. La edad materna mantiene un patrón similar al observado en el primer trimestre, aumentando el riesgo a partir de los 37 años. El perímetro abdominal presenta escasa relevancia discriminativa, mientras que los marcadores de alerta estructural muestran importancia localizada, probablemente condicionada por su baja prevalencia, pero alta asociación con casos positivos, especialmente cardiopatía congénita (mCOR) y otras anomalías estructurales (mOTR).

Teniendo en cuenta la alta correlación ($r = 0.82$) entre diámetro biparietal y el perímetro cefálico, se plantea evaluar visualmente el ALE conjunto:




Figura 15 ALE de la interacción DBP y perímetro cefálico

La Figura 15 representa el efecto de conjunto entre ambas variables, mientras que los contornos rojo y azul delimitan aproximadamente el 90% de densidad de casos y controles, respectivamente. Dentro de la región con soporte suficiente, se observa un efecto positivo moderado cuando tanto el diámetro biparietal como el perímetro cefálico presentan valores inferiores a la mediana esperada para la edad gestacional.

En conjunto, la interpretación sugiere que biometrías craneales reducidas o patrones compatibles con braquicefalia se asocian a un incremento relativo del riesgo predicho. Aunque la interpretación debe realizarse con cautela por el desbalance de clases y menor soporte en regiones periféricas.

4.4. Escenario combinado

Este escenario evalúa si la integración simultánea de biomarcadores del primer trimestre y variables ecográficas del segundo trimestre aporta capacidad predictiva adicional respecto al modelado independiente por trimestre.

En este contexto, la regresión logística fue finalmente seleccionada como modelo óptimo, al presentar mejor equilibrio entre discriminación, calibración y estabilidad entre folds. En particular, alcanzó un tpr5 de 0.84, una precisión media de 0.76 y un Brier Skill Score ponderado de 0.61.




Figura 16 Comparación de modelos en escenario combinado

Tabla 5 Métricas OOF en el escenario combinado

	Sensibilidad	Especificidad	G mean	Tpr5	WBSS	AP
logreg «	0.85 ± 0.07	0.95 ± 0.01	0.90 ± 0.04	0.84 ± 0.06	0.61 ± 0.17	0.76 ± 0.07
SVC	0.87 ± 0.08	0.95 ± 0.01	0.91 ± 0.04	0.87 ± 0.08	0.58 ± 0.20	0.75 ± 0.09
RF	0.63 ± 0.11	0.99 ± 0.01	0.79 ± 0.14	0.82 ± 0.14	0.62 ± 0.12	0.75 ± 0.11
QDA	0.84 ± 0.13	0.95 ± 0.01	0.89 ± 0.09	0.84 ± 0.15	0.52 ± 0.18	0.71 ± 0.16
NB	0.72 ± 0.19	0.95 ± 0.02	0.82 ± 0.10	0.70 ± 0.21	0.25 ± 0.06	0.48 ± 0.09
KNN	0.34 ± 0.18	1.00 ± 0.03	0.56 ± 0.18	0.66 ± 0.20	0.35 ± 0.10	0.50 ± 0.12

En el escenario combinado, la regresión logística y SVC vuelven a posicionarse como los clasificadores con mejor rendimiento global, superando al resto tanto en discriminación como en calibración. Aunque las diferencias son reducidas, la regresión logística se seleccionó como modelo final por presentar mejores valores de WBSS y AP, junto con una menor variabilidad entre folds, lo que sugiere una solución más estable y mejor calibrada.




Figura 17 Calibración de escenario combinado

La curva de calibración de la regresión logística (Figura 17) está relativamente bien calibrada, aunque con algunos tramos donde infravalora el riesgo. La aplicación de la calibración es, en general, una bajada de las probabilidades medias y altas. La transformación puede considerarse calibrada ($Z = -1.044$).

La distribución de probabilidades entre las clases es similar a los anteriores y la curva de log LR+ crece de forma constante pero suave. Con respecto a las métricas, el escenario combinado es más diagnosticable ($tpr5 = 0.84$) que el primer trimestre ($tpr5 = 0.83$) o segundo trimestre ($tpr5 = 0.77$).

Comparación de arquitecturas de stacking con el escenario combinado:

Como etapa final del experimento, se comparó el mejor modelo directo entrenado sobre el conjunto combinado T1+T2 frente a dos estrategias de *stacking* basadas en las predicciones OOF de los mejores modelos independientes de T1 y T2. Esta comparación permite evaluar si la combinación jerárquica de predicciones conserva mejor la información complementaria de ambos trimestres que el entrenamiento directo sobre todas las variables.




Figura 18 Comparación de STACK

Tabla 6 Métricas en TEST con bootstrap

	T12	STACK	STACK+PT
Sensibilidad	0.81 [0.62, 1]	0.88 [0.69, 1]	0.81 [0.62, 1]
Especificidad	0.95 [0.92, 0.97]	0.95 [0.93, 0.97]	0.95 [0.92, 0.97]
G mean	0.88 [0.76, 0.97]	0.91 [0.81, 0.98]	0.88 [0.76, 0.97]
Tpr5	0.63 [0.6, 1]	0.81 [0.68, 1]	0.69 [0.61, 1]
WBSS	0.54 [0.36, 0.73]	0.48 [0.28, 0.69]	0.56 [0.36, 0.76]
AP	0.70 [0.49, 0.88]	0.77 [0.56, 0.93]	0.74 [0.54, 0.92]
LR+	15.17 [9.70, 25.87]	19.06 [12.25, 33.48]	15.17 [9.83, 26.25]
Umbral	0.072	0.030	0.061

En la Figura 18 y Tabla 6 se presenta la evaluación del desempeño de los modelos de ensamble en el conjunto de test independiente, utilizando la técnica de *Bootstrap* para obtener intervalos de confianza robustos. El análisis comparativo se centra en tres configuraciones: la regresión logística del escenario conjunto de los trimestres (T12) anteriormente descrito, la arquitectura de *stacking* básica sobre las predicciones de los modelos de primer (SVC) y segundo trimestre (RF) individuales, y el *stacking* con paso de variables originales (STACK+PT).

Los resultados obtenidos en el conjunto test demuestran que la arquitectura STACK constituye la estrategia más eficiente entre las alternativas evaluadas, basándonos en las estimaciones puntuales. En particular, alcanza una sensibilidad, g-mean, tpr5, AP y LR+ más elevados, que, en conjunto, indican una mejor capacidad para equilibrar detección de casos positivos y correcta clasificación de controles bajo restricción clínica de bajo falso positivo, reforzando la utilidad del ensamblado jerárquico frente al entrenamiento directo sobre el conjunto integrado de variables.

Desde una perspectiva de utilidad clínica, el STACK destaca con una ratio de verosimilitud de la clase de 19.06, superior al resto de modelos, pero no significativamente mayor, ya que los intervalos de confianza son lo bastante anchos debido a los pocos casos positivos en test.

Con respecto a la interpretabilidad:




Figura 19 SHAP resumen de STACK




Figura 20 Efectos ALE de STACK

En el SHAP (Figura 19) se observa que la longitud del fémur (LF) y la translucencia nucal (sn) son las variables con mayor impacto en la predicción. En concordancia con los modelos individuales, el acortamiento femoral ($\text{MoM} < 0.95$) y una aumentada translucencia ($\text{MoM} > 1.28$) están asociados a un mayor riesgo. Esta relación se clarifica en los gráficos ALE 1D (Ilustración 20), que muestran decrementos e incrementos abruptos en esas zonas. Valores reducidos de PAPP-A con respecto la mediana para la edad gestacional ($\text{MoM} < 0.36$), edad materna mayor que 37 años, HCG aumentada ($\text{MoM} > 2.01$), perímetro cefálico ($\text{MoM} < 0.93$) y DBP reducidos con respecto a la mediana para la edad gestacional son factores que aumentan el riesgo.

5. Discusión

5.1. Plausibilidad clínica de las variables predictoras

La solidez de los modelos desarrollados, especialmente la arquitectura STACK, se ve reforzada por el hecho de que las variables con mayor peso predictivo concuerdan con su capacidad discriminativa marginal y coinciden plenamente con los marcadores biológicos descritos en la literatura.

El acortamiento del fémur es uno de los rasgos fenotípicos con más capacidad discriminativa ($AUC = 0.83$) que presenta la correlación negativa más fuerte ($r = -0.35$) con la clase, siendo además la variable más influyente en las predicciones. Este hallazgo es clínicamente plausible, ya que estudios señalan que el acortamiento de huesos largos como el fémur o el húmero está presente en el 24.4% de los casos con SD frente a un 4.7% de los controles [35].

La translucencia nuchal presentó una de las mayores capacidades discriminativas ($AUC = 0.81$) y una correlación positiva con la clase ($r = 0.30$). Según el modelo, un aumento en el grosor de la translucencia nuchal a partir de un $MoM > 1.28$ se asocia directamente con un incremento del riesgo de SD. Este hallazgo es coherente con la literatura [12].

Marcadores bioquímicos: La importancia asignada a la PAPP-A y HCG y su dirección es biológicamente consistente con los perfiles endocrinos típicos del SD.

La PAPP-A es la variable con mayor capacidad discriminativa ($AUC = 0.86$), mostrando una correlación negativa ($r = -0.27$) y a su vez la tercera variable más influyente en las predicciones. Valores menores que la mediana ($MoM < 0.36$) se asocian a un mayor riesgo. Esto es coherente con estudios donde estiman que los niveles en casos afectados suelen estar un 60% por debajo que los controles ($MoM < 0.40$) [2].

El HCG no es tan relevante como podría esperarse, pues tiene capacidad discriminativa de $AUC = 0.71$ con correlación positiva ($r = 0.16$) con la clase. Es la quinta variable más influyente en la predicción, en la que niveles altos por encima de la mediana ($MoM > 2.01$) se asocian a un mayor riesgo. Esto es coherente con estudios donde estiman que los niveles en casos afectados suelen estar un 80% más elevados que los controles ($MoM > 1.80$) [2].

La edad materna está consolidada como un factor de riesgo independiente ($AUC = 0.72$), siendo la cuarta variable más influyente en las predicciones. Se observa un incremento significativo del riesgo a partir de los 37 años, lo que concuerda plenamente con la evidencia epidemiológica en la que se estima que una edad mayor que 35 años se considera de riesgo [2].

Las biometrías craneales como el perímetro cefálico ($AUC = 0.74$) y el diámetro biparietal, siendo la sexta y séptima variable más influyente en las predicciones, mostraron que valores reducidos ($PERCEFAL MoM < 0.93$) aumentan significativamente el riesgo predicho. Estas observaciones son consistentes con los patrones de microcefalia y braquicefalia característicos en el 60% y 40% de los casos de SD respectivamente [36].

Finalmente, de los marcadores de alerta considerados, la cardiopatía congénita presenta la mayor correlación ($r = 0.34$) entre ellas. Esta asociación es coherente, dado que aproximadamente el 44% de los neonatos con SD presentan malformaciones cardíacas estructurales [37].

5.2. Comparativa y posicionamiento

El rendimiento alcanzado por el modelo STACK, con una sensibilidad del 81% para una tasa de falsos positivos fija del 5% (tpr5) en el conjunto de test, sitúa a esta herramienta en una posición no competitiva frente a los estándares clínicos y los avances recientes en aprendizaje automático. El “Integrated test” obtiene una tasa de detección del 94% para un 5% de FPR. Si bien la cifra se aproxima, debería tenerse en cuenta la variabilidad intrínseca de trabajar con muestras limitadas, la falta de algunas variables relevantes o la tecnología aplicada. Sin embargo, el modelo del primer trimestre es similar al test convencional (tpr5 0.83 vs 0.85), y el modelo de segundo trimestre supera al triple test (0.77 vs 0.65) o al cuádruple test (0.77 vs 0.76).

A diferencia de los modelos de “caja negra” de ML o IA que carecen de transparencia, este estudio integra un marco de interpretabilidad global y local mediante ALE y SHAP. La interpretación de estos gráficos permite validar efectos locales sin el sesgo de extrapolación que presentan los gráficos de dependencia parcial (PDP) en presencia de variables correlacionadas.

La interpretación de la salida del modelo puede entenderse como una mera clasificación binaria para el cribado, o como estimadores de riesgo calibrados, confirmados estadísticamente, si se tiene en cuenta la probabilidad predicha.

Desde una perspectiva clínica, las curvas de densidad de probabilidades y las curvas del logaritmo de la razón de verosimilitud en los escenarios individuales validan que incrementos en la probabilidad predicha se traducen en un aumento real del riesgo relativo. Por consiguiente, siendo STACK una regresión logística sobre la predicción de modelos calibrados, es por definición calibrado e interpretable bajo la prevalencia de la población de estudio. Este modelo final obtiene una ratio de verosimilitud de 19.06 bajo un umbral de 0.03, lo que implica que la probabilidad a posteriori en la población de estudio con prevalencia 5% (1 de 20) asciende al 50% (1 de 2), pero en la prevalencia real de aproximadamente 0.125% (1 de 800) asciende al 2.33% (1 de 43) (PPV).

Esta consistencia probabilística es fundamental para que el facultativo pueda utilizar el resultado como una alarma y como una medida de la certidumbre diagnóstica, cabe destacar que la principal finalidad de esta herramienta en caso desplegarse en producción, será como una segunda opinión y nunca prevaleciendo sobre la opinión de los facultativos. Para una integración efectiva en la práctica asistencial, se derivan las siguientes recomendaciones basadas en los resultados:

- Ajuste de umbrales operativos: Se desaconseja el uso del umbral por defecto (0.5) recomendándose fijar el punto de decisión según la tasa de falsos positivos clínicamente aceptable (ej. para 5%, 0.03), tal como se ha implementado en el estudio.
- Probabilidades guiadas por explicabilidad local: El uso de herramientas de explicabilidad debe acompañar al riesgo numérico, permitiendo al clínico confirmar sobre qué marcadores se ha basado dicha predicción.

- Validación local continua: Dado que el rendimiento de estos modelos es sensible a la prevalencia de la población de entrenamiento (5%), se recomienda realizar recalibraciones periódicas si la prevalencia asistencial del centro difiere significativamente.

Aunque la literatura y la práctica clínica habitual priorizan la minimización de los falsos positivos principalmente por motivos económicos y por el riesgo asociado a procedimientos invasivos, esta focalización puede resultar incompleta desde una perspectiva ética y clínica. Los falsos negativos, aunque menos visibles a nivel poblacional, generan un daño individual más difícil de cuantificar: proporcionan una falsa sensación de seguridad que puede impedir el acceso a pruebas confirmatorias y asesoramiento genético, limitando así la posibilidad de una toma de decisiones informada durante el embarazo. Desde esta perspectiva, el impacto de los falsos negativos introduce una dimensión ética más compleja que implica valores relacionados con la autonomía reproductiva variables entre contextos culturales y familiares.

5.3. Limitaciones

Este estudio presenta varias limitaciones que deben considerarse al interpretar los resultados obtenidos y valorar su aplicabilidad clínica.

En primer lugar, la principal restricción metodológica deriva del tamaño muestral disponible, especialmente de los casos afectos. Aunque este problema es inherente a la baja prevalencia del SD y se ha mitigado mediante validación cruzada estratificada y optimización específica para escenarios desbalanceados, el número limitado de casos afecta tanto a la estabilidad de las estimaciones como a la capacidad de generalización del modelo.

De forma conjunta, el poder predictivo alcanzable está condicionado por la propia señal contenida en los datos y por la ausencia de algunas variables clínicamente relevantes no disponibles en la base de datos: como el estriol no conjugado (uE3), inhibina A, que son componentes estándar de los protocolos de cribado como el “triple” o “cuádruple test” [2]; antecedentes maternos, comorbilidades o factores ambientales como tabaquismo o diabetes son predictores reconocidos y factores de ajuste necesarios en el cálculo, ya que alteran significativamente las concentraciones de los marcadores bioquímicos [8,13,15].

En segundo lugar, el cálculo de múltiplos de la mediana se realizó usando estándares externos de referencia, como INTERGROWTH-21st y FMF, debido a la ausencia de densidad muestral suficiente para construir tablas de referencia específicas sobre la población de estudio. Aunque esta aproximación permite normalizar adecuadamente biomarcadores y biometrías, introduce una posible fuente de sesgo por discrepancias poblacionales entre cohortes de referencia y población analizada.

Otra limitación relevante es la pérdida de información temporal que se podría haber abordado desde un enfoque longitudinal y suficientes datos. Aunque la base de datos contiene mediciones correspondientes a distintos momentos del embarazo, el diseño de este trabajo es transversal. En consecuencia, no se explotan posibles patrones dinámicos de evolución de biomarcadores o biometrías fetales que podrían aportar capacidad predictiva adicional.

Demográficamente, no se dispone de información suficiente sobre posibles sesgos sociodemográficos o composición étnica de la cohorte. Esta limitación resulta relevante en este contexto, ya que diversos estudios han documentado limitaciones en la

generalización de biomarcadores séricos entre poblaciones asiáticas o afrocaribeñas, debido a diferencias genéticas o fisiológicas que pueden modificar los valores esperados de referencia [8,11].

Por último, el alcance clínico del trabajo se restringe exclusivamente al cribado del SD (trisomía 21). Sin embargo, en la práctica clínica habitual el cribado prenatal se orienta simultáneamente a las trisomías 13, 18 y 21. La ausencia de un enfoque multiclase limita el potencial de la herramienta como sustituto integral de estrategias de cribado convencionales, manteniendo la necesidad de interpretación clínica complementaria y métodos diagnósticos adicionales.

6. Conclusiones y trabajos futuros

6.1. Conclusiones

El presente trabajo ha permitido diseñar, implementar y evaluar un marco de aprendizaje automático avanzado para el cribado prenatal de la trisomía 21, integrando información bioquímica, ecográfica y materna procedente de distintas etapas del embarazo. Los resultados obtenidos evidencian que la combinación estructurada de fuentes heterogéneas permite superar parcialmente las limitaciones de los enfoques convencionales.

Las principales conclusiones derivadas del estudio pueden resumirse en cuatro hallazgos fundamentales:

Superioridad del ensamblado jerárquico

La conclusión metodológica más relevante es que la arquitectura STACK, construida a partir de un modelo SVC para el primer trimestre y un Random Forest para el segundo, mostró un rendimiento superior al entrenamiento directo sobre el conjunto integrado de las variables. En evaluación externa, este modelo alcanzó una sensibilidad del 81% bajo una restricción de 5% de falsos positivos (tpr5), lo que confirma que la combinación jerárquica de predicciones preserva mejor la información complementaria a ambos trimestres.

Valor incremental de la integración trimestral

Los resultados confirman que la integración procedente de los distintos modelos trimestrales mejora el rendimiento respecto al modelado independiente por trimestre. En particular, el escenario combinado y, posteriormente, la estrategia de stacking, muestran que los biomarcadores séricos del primer trimestre y la biométricas ecográficas del segundo aportan información parcialmente complementaria, reforzando el valor clínico del cribado integrado.

Coherencia biológica de los modelos

El análisis de interpretabilidad mediante SHAP y ALE indica que los modelos capturaron patrones clínicamente plausibles y consistentes con la literatura especializada. Entre las variables más influyentes destacan la disminución de la PAPP-A, el incremento de la translucencia nuchal, la edad materna avanzada y el acortamiento fetal, todos ellos biomarcadores ampliamente asociados al riesgo de SD.

Fiabilidad probabilística para toma de decisiones

La incorporación de procedimientos de calibración probabilística permitió transformar las puntuaciones brutas de los clasificadores en estimaciones de riesgo más fiables e interpretables. Este aspecto resulta especialmente relevante en un contexto de cribado prenatal, donde la utilidad clínica del modelo depende de su capacidad discriminativa y de la calidad de las probabilidades para apoyar decisiones posteriores de seguimiento o confirmación diagnóstica.

6.2. Consecución de objetivos

Se considera que los objetivos planteados al inicio del trabajo se han alcanzado de forma satisfactoria.

Se cumplió el objetivo de analizar y caracterizar las variables clínicas y ecográficas disponibles en el screening prenatal del síndrome de Down, evaluando su relevancia y distribución en la población de estudio. Para ello, se realizó una descripción estadística exhaustiva de la cohorte, acompañada de análisis exploratorios y evaluación de la capacidad discriminativa marginal, lo que permitió identificar los biomarcadores y variables ecográficas con mayor relevancia clínica y predictiva.

Con respecto al objetivo de desarrollar y evaluar modelos predictivos para la estimación del riesgo durante el embarazo, se implementaron seis familias de algoritmos de aprendizaje automático, comparadas bajo un esquema riguroso de validación cruzada anidada, calibración de probabilidades y evaluación final sobre el conjunto de test, complementada con técnicas Bootstrap para estimar la estabilidad y robustez del rendimiento.

Se alcanzó el objetivo de analizar críticamente las decisiones metodológicas del proceso de modelización y proponer mejoras potenciales. Se evaluaron decisiones relevantes de preprocesado y diseño experimental, incluyendo la transformación a múltiplos de la mediana, corrección por peso materno, tratamiento de valores extremos, comparación de estrategias de muestreo y calibración de probabilidades.

La planificación metodológica se formuló desde el inicio con suficiente flexibilidad para incorporar mejoras progresivas durante el desarrollo del trabajo. En este sentido, aunque las líneas generales previstas se han mantenido, se incorporaron elementos metodológicos no contemplados inicialmente, como el uso de técnicas de interpretabilidad basadas en SHAP y ALE, integradas una vez finalizada la fase principal de modelización.

Respecto a los impactos planteados en la sección 1.3, el impacto ambiental negativo se ha mantenido mínimo y bajo control, cumpliendo con la previsión inicial. La ausencia de arquitecturas de aprendizaje profundo y un entorno de trabajo local han permitido un entrenamiento con bajo consumo energético. Con respecto a mejorar la toma de decisiones, puede ser un logro potencial, pero de momento el modelo no es comercial.

En relación con el impacto potencial sobre la toma de decisiones clínicas, los resultados obtenidos sugieren utilidad futura como herramienta de apoyo al cribado prenatal; no obstante, el modelo desarrollado constituye actualmente una prueba metodológica y no una solución directamente transferible a la práctica clínica o comercial.

El riesgo de uso indebido o interpretación incorrecta se abordó mediante calibración de probabilidades, análisis explícito de la fiabilidad y aportación de buenas prácticas para interpretación y uso responsable de la herramienta.

Por último, el objetivo de garantizar aplicabilidad equitativa entre distintos subgrupos poblacionales no puede considerarse alcanzado, debido a la homogeneidad de la muestra utilizada. Al proceder los datos exclusivamente de un centro local, persisten limitaciones relevantes en términos de generalización geográfica, poblacional o étnica.

6.3. Trabajos futuros

A pesar de los buenos resultados obtenidos, este estudio abre nuevas líneas de investigación orientadas a superar las limitaciones identificadas y ampliar el alcance clínico del modelo desarrollado:

Una extensión natural consiste en reformular el problema desde un enfoque multiclase, permitiendo la detección simultánea de trisomías 21, 18 y 13, así como potencialmente otras anomalías cromosómicas relevantes. Esta ampliación alinearía el modelo con parte de la práctica clínica real, en la que el cribado prenatal se orienta de forma conjunta a múltiples patologías fetales.

Futuras investigaciones podrían explorar explícitamente la dimensión temporal en la naturaleza de los datos. Aunque en este trabajo el problema se abordó desde una perspectiva transversal y por bloques trimestrales, la disponibilidad de mediciones secuenciales permitiría modelar trayectorias intra-embarazo, velocidades de crecimiento fetal o la evolución dinámica de biomarcadores séricos y ecográficos. Este enfoque longitudinal podría capturar patrones actualmente no explotados y mejorar la capacidad predictiva del sistema.

Sería deseable incorporar variables clínicas no disponibles en la cohorte analizada, como el estriol no conjugado (uE3), inhibina A, antecedentes obstétricos, comorbilidades maternas o factores de estilo de vida. La integración de estas variables podría enriquecer la representación del riesgo y aproximar el modelo a protocolos clínicos más completos.

Por último, una línea metodológica especialmente interesante consiste en explorar estrategias que integren nuevos datos en su aprendizaje, en la literatura lo podemos encontrar con nombres como *Reinforcement Learning*, *Lifelong learning*, *online learning* o *batch learning* [38–41]. Dado el elevado coste asociado al etiquetado y disponibilidad limitada de casos positivos, estos enfoques permitirían priorizar de forma iterativa la incorporación de observaciones más informativas, optimizando el uso de nuevos datos y facilitando una mejora progresiva del rendimiento del modelo en escenarios reales de actualización continua.

7. Glosario

- **SD, T21:** Síndrome de Down, anomalía cromosómica caracterizada por la presencia de una copia extra del cromosoma 21.
- **PAPP-A:** Proteína plasmática A asociada al embarazo.
- **hCG, β -hCG libre:** Gonadotropina coriónica humana.
- **NT, sn:** Translucencia nuchal, espesor del espacio relleno de líquido en la zona posterior del cuello fetal.
- **CRL:** Longitud cefalocaudal, medida de la longitud del feto (rabadilla – cráneo).
- **EG:** Edad gestacional, tiempo de embarazo medido en días o semanas desde la última regla.
- **MoM:** Múltiplos de la mediana, medida estandarizada que expresa cuánto se aleja un valor observado de la mediana esperada.
- **DBP:** Diámetro biparietal, medida de la distancia entre los huesos parietales del cráneo fetal.
- **LF:** longitud femoral, medida de la longitud del fémur del feto.
- **OOF:** *Out-of-fold*, predicciones realizadas sobre particiones de datos que no fueron utilizadas durante el entrenamiento de esa instancia específica del modelo.
- **Tpr5, TPR@5FPR:** *True positive rate at 5% false positive rate*, sensibilidad del modelo fijando una tasa de falsos positivos del 5%.
- **AP:** Precisión media, calculada como el área bajo la curva precisión - sensibilidad.
- **LR+:** Razón de verosimilitud positiva, indica cuánto más probable es un resultado positivo en un caso afecto frente a uno sano.
- **FISABIO:** Fundación para el Fomento de la Investigación Sanitaria y Biomédica de la Comunitat Valenciana.
- **ISUOG:** Sociedad Internacional de Ultrasonido en Obstetricia y Ginecología.
- **FMF:** Fundación de Medicina Fetal.
- **RGPD:** Reglamento General de Protección de Datos.

8. Bibliografía

- [1] Sifakis S, Papantoniou N, Kappou D, et al. Noninvasive prenatal diagnosis of Down syndrome: current knowledge and novel insights. *J Perinat Med* 2012;40:319–27. <https://doi.org/10.1515/jpm-2011-0282>.
- [2] Wald NJ, Hackshaw AK. Advances in antenatal screening for Down syndrome. *Baillieres Best Pract Res Clin Obstet Gynaecol* 2000;14:563–80. <https://doi.org/10.1053/beog.2000.0097>.
- [3] Hassan N, Slight R, Morgan G, et al. Road map for clinicians to develop and evaluate AI predictive models to inform clinical decision-making. *BMJ Health Care Inform* 2023;30. <https://doi.org/10.1136/bmjhci-2023-100784>.
- [4] Reglamento (UE) 2016/679 del Parlamento Europeo y del Consejo, de 27 de abril de 2016, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos y por el que se deroga la Directiva 95/36/CE (RGPD). 2018.
- [5] Hall M, Maaten L van der, Gustafson L, et al. A Systematic Study of Bias Amplification 2022.
- [6] Subramonian A, Bell SJ, Sagun L, et al. An Effective Theory of Bias Amplification 2025.
- [7] Sadegh-Zadeh S-A, Mamalo A, Saadat S, et al. Multi-Task Machine Learning for Prenatal Risk Stratification: Integrating Biomarkers, Maternal Age, and Ultrasound Measurements to Predict the Risk of Down Syndrome, Trisomy 18, Trisomy 13, and Neural Tube Defects. *Front Biomed Signal Process* 2025;1:24–36. <https://doi.org/10.62762/FBSP.2025.954863>.
- [8] Alonso E, Beristain A, Burgos J, et al. Comparison of Machine Learning Algorithms to Predict Down Syndrome During the Screening of the First Trimester of Pregnancy. *Appl Sci* 2025;15:5401. <https://doi.org/10.3390/app15105401>.
- [9] Koivu A, Korpimäki T, Kivelä P, et al. Evaluation of machine learning algorithms for improved risk assessment for Down's syndrome. *Comput Biol Med* 2018;98:1–7. <https://doi.org/10.1016/j.compbiomed.2018.05.004>.
- [10] Li L, Liu W, Zhang H, et al. Down Syndrome Prediction Using a Cascaded Machine Learning Framework Designed for Imbalanced and Feature-correlated Data. *IEEE Access* 2019;7:97582–93. <https://doi.org/10.1109/ACCESS.2019.2929681>.
- [11] He F, Lin B, Mou K, et al. A machine learning model for the prediction of down syndrome in second trimester antenatal screening. *Clin Chim Acta* 2021;521:206–11. <https://doi.org/10.1016/j.cca.2021.07.015>.
- [12] Wright D, Kagan KO, Molina FS, et al. A mixture model of nuchal translucency thickness in screening for chromosomal defects. *Ultrasound Obstet Gynecol* 2008;31:376–83. <https://doi.org/10.1002/uog.5299>.
- [13] Wright A, Guerra L, Pellegrino M, et al. Maternal serum PAPP-A and free β -hCG at 12, 22 and 32 weeks' gestation in screening for pre-eclampsia. *Ultrasound Obstet Gynecol* 2016;47:762–7. <https://doi.org/10.1002/uog.15849>.
- [14] Lopez-Garcia LM, Bataller-Calatayud A, Sanz-Marti C, et al. Probabilistic machine learning methods for Down syndrome prenatal screening: unified first and second trimester markers multivariate bayesian risk model versus current contingent sequential strategy. 2021 Int Symp Biomed Eng Comput Biol 2021.
- [15] Hu L, Xu M, Li Y, et al. Ensemble learning-driven hybrid prediction model for improved prenatal down's syndrome screening: a comparative study with laboratory-based median equations. *Clin Chim Acta* 2026;578:120519. <https://doi.org/10.1016/j.cca.2025.120519>.
- [16] Yasin S, Ahmed S, Shahbaz M, et al. Trisomy 21 Testing in Second Trimester: Reliability Comparison of Triple and Quadruple Testing in Pakistan 2023;17. <https://doi.org/https://doi.org/10.53350/pjmhs2023173492>.

- [17] Salomon LJ, Alfirevic Z, Berghella V, et al. Practice guidelines for performance of the routine mid-trimester fetal ultrasound scan. *Ultrasound Obstet Gynecol* 2011;37:116–26. <https://doi.org/10.1002/uog.8831>.
- [18] Papageorgiou AT, Ohuma EO, Altman DG, et al. International standards for fetal growth based on serial ultrasound measurements: the Fetal Growth Longitudinal Study of the INTERGROWTH-21st Project. *The Lancet* 2014;384:869–79. [https://doi.org/10.1016/S0140-6736\(14\)61490-2](https://doi.org/10.1016/S0140-6736(14)61490-2).
- [19] Neveux LM, Palomaki GE, Larrivee DA, et al. REFINEMENTS IN MANAGING MATERNAL WEIGHT ADJUSTMENT FOR INTERPRETING PRENATAL SCREENING RESULTS. *Prenat Diagn* 1996;16:1115–9. [https://doi.org/10.1002/\(SICI\)1097-0223\(199612\)16:12%3C1115::AID-PD3%3E3.0.CO;2-6](https://doi.org/10.1002/(SICI)1097-0223(199612)16:12%3C1115::AID-PD3%3E3.0.CO;2-6).
- [20] Spencer K, Bindra R, Nicolaides KH. Maternal weight correction of maternal serum PAPP-A and free beta-hCG MoM when screening for trisomy 21 in the first trimester of pregnancy. *Prenat Diagn* 2003;23:851–5. <https://doi.org/https://doi.org/10.1002/pd.708>.
- [21] Rousseeuw PJ, Croux C. Alternatives to the Median Absolute Deviation. *J Am Stat Assoc* 1993;88:1273–83. <https://doi.org/10.1080/01621459.1993.10476408>.
- [22] Chawla N, Bowyer K, Hall L, et al. SMOTE: Synthetic Minority Over-sampling Technique. *J Artif Intell Res* 2002;16:321–57. <https://doi.org/10.1613/jair.953>.
- [23] He H, Bai Y, Garcia E, et al. ADASYN: Adaptive Synthetic Sampling Approach for Imbalanced Learning. *Proc. Int. Jt. Conf. Neural Netw.*, 2008, p. 1322–8. <https://doi.org/10.1109/IJCNN.2008.4633969>.
- [24] Wilson DL. Asymptotic Properties of Nearest Neighbor Rules Using Edited Data. *IEEE Trans Syst Man Cybern* 1972;2:408–21.
- [25] Ojala M, Garriga GC. Permutation Tests for Studying Classifier Performance. 2009 Ninth IEEE Int. Conf. Data Min., Miami Beach, FL, USA: IEEE; 2009, p. 908–13. <https://doi.org/10.1109/ICDM.2009.108>.
- [26] Akiba T, Sano S, Yanase T, et al. Optuna: A Next-generation Hyperparameter Optimization Framework 2019. <https://doi.org/10.48550/ARXIV.1907.10902>.
- [27] Papathanasiou J, Ploskas N. TOPSIS. *Mult. Criteria Decis. Aid*, vol. 136, Cham: Springer International Publishing; 2018, p. 1–30. https://doi.org/10.1007/978-3-319-91648-4_1.
- [28] Platt J. Probabilistic Outputs for Support Vector Machines and Comparisons to Regularized Likelihood Methods. *Adv Large Margin Classif* 2000;10.
- [29] Kull M, Silva Filho TM, Flach P. Beyond sigmoids: How to obtain well-calibrated probabilities from binary classifiers with beta calibration. *Electron J Stat* 2017;11. <https://doi.org/10.1214/17-EJS1338SI>.
- [30] Bröcker J, Smith LA. Increasing the Reliability of Reliability Diagrams. *Weather Forecast* 2007;22:651–61. <https://doi.org/10.1175/WAF993.1>.
- [31] Spiegelhalter DJ. Probabilistic prediction in patient management and clinical trials. *Stat Med* 1986;5:421–33. <https://doi.org/10.1002/sim.4780050506>.
- [32] Doshi-Velez F, Kim B. Towards A Rigorous Science of Interpretable Machine Learning 2017. <https://doi.org/10.48550/ARXIV.1702.08608>.
- [33] Apley DW, Zhu J. Visualizing the Effects of Predictor Variables in Black Box Supervised Learning Models. *J R Stat Soc Ser B Stat Methodol* 2020;82:1059–86. <https://doi.org/10.1111/rssb.12377>.
- [34] Lundberg SM, Lee S-I. A Unified Approach to Interpreting Model Predictions. In: Guyon I, Luxburg UV, Bengio S, et al., editors. *Adv. Neural Inf. Process. Syst.*, vol. 30, Curran Associates, Inc.; 2017.
- [35] Nyberg DA, Resta RG, Luthy DA, et al. Humerus and femur length shortening in the detection of Down's syndrome. *Am J Obstet Gynecol* 1993;168:534–8. [https://doi.org/10.1016/0002-9378\(93\)90487-4](https://doi.org/10.1016/0002-9378(93)90487-4).

- [36] Slomic AM, Bernier JP, Morissette J, et al. A craniometric study of Trisomy 21 (T 21). Bull Mém Société Anthropol Paris 1990;2:189–202. <https://doi.org/10.3406/bmsap.1990.1731>.
- [37] Freeman SB, Taft LF, Dooley KJ, et al. Population-based study of congenital heart defects in Down syndrome. Am J Med Genet 1998;80:213–7.
- [38] Chen Z, Liu B. Lifelong Machine Learning. Cham: Springer International Publishing; 2017. <https://doi.org/10.1007/978-3-031-01575-5>.
- [39] Pan C, Yang X, Li Y, et al. A Survey of Continual Reinforcement Learning 2026. <https://doi.org/10.48550/arXiv.2506.21872>.
- [40] Shalev-Shwartz S, Singer Y, Ng AY. Online and batch learning of pseudo-metrics. Twenty-First Int. Conf. Mach. Learn. - ICML 04, Banff, Alberta, Canada: ACM Press; 2004, p. 94. <https://doi.org/10.1145/1015330.1015376>.
- [41] Hoi SCH, Sahoo D, Lu J, et al. Online learning: A comprehensive survey. Neurocomputing 2021;459:249–89. <https://doi.org/10.1016/j.neucom.2021.04.112>.

9. Anexo

El código fuente del trabajo está disponible en el siguiente repositorio GitHub: https://github.com/davidgherr/TFM_biostat